

分类号

密级

UDC

编号

南方医科大学

硕士学位论文

基于深度学习的 CT 图像肺动脉栓塞分割方法研究

与自动分割系统实现

Research on Deep Learning-Based Segmentation Methods for

Pulmonary Artery Embolism in CT Images

and Implementation of an Automated Segmentation System

肖若琳

导师姓名

阳维 教授

专业名称

电子信息

培养类型

全日制专业型

论文提交日期


2025 年 5 月

基于深度学习的 CT 图像肺动脉栓塞分割方法研究
与自动分割系统实现
**Research on Deep Learning-Based Segmentation Methods for
Pulmonary Artery Embolism in CT Images and Implementation
of an Automated Segmentation System**

课题来源： 国家自然科学基金（82172020，82472050），广东省自然科学基金（2023A1515011291）

学 位 申 请 人	肖若琳
导 师 姓 名	阳维
专 业 名 称	电子信息
培 养 类 型	全日制专业型
培 养 层 次	硕士研究生
所 在 学 院	生物医学工程学院

答辩委员会主席	战荫伟	教授
答辩委员会委员	何 基	教授
	杨 丰	教授
	路利军	教授
	程胜华	教授



2025 年 5 月 17 日 广州

基于深度学习的 CT 图像肺动脉栓塞分割方法研究与自动分割系统实现

硕士研究生：肖若琳

指导教师：阳维教授

摘 要

肺栓塞是一种由内源性或外源性栓子阻塞肺动脉及其分支引起的临床综合征，严重时可导致右心功能受损、器官衰竭甚至死亡。肺栓塞的早期诊断和及时干预对降低其致残率和病死率至关重要。然而，肺栓塞的临床表现缺乏特异性，且目前依赖 CT 肺动脉造影（CT pulmonary angiography, CTPA）作为诊断金标准，其人工诊断过程耗时且易受主观因素影响，导致较高的漏诊率和误诊率。近年来，深度学习技术在医学影像领域的应用为肺栓塞的自动诊断提供了新的解决方案。

本文围绕肺栓塞的自动分割展开研究，提高诊断效率、减少误诊率，并为临床医生提供客观的病情评估依据。研究内容主要包括以下三个方面：

（1）基于 CTPA 图像的肺栓塞自动分割方法研究：针对现有方法在肺栓塞分割中的局限，提出了一种面向 CT 诊断模式的交叉难度感知网络。该网络通过模拟多模态 CT 图像协作诊断模式，学习肺栓塞与周围组织的强度差异，有效减少假阳性分割，尤其在处理小尺寸及组织间相似区域时表现突出。此外，引入了交叉难度感知策略和难度感知损失函数，增强了对形态不规则和位置多变区域的关注。实验结果表明，该方法在肺栓塞分割任务中优于现有技术。

（2）基于非增强 CT 图像（Non-Contrast Computed Tomography, NCCT）

的肺栓塞自动分割方法研究：针对 CTPA 检查中对比剂可能引发的风险，提出了一种基于自监督学习的 NCCT 肺栓塞分割方法。通过多任务对比剂掩码图像建模框架，该方法能够在无需对比剂的情况下，有效捕捉图像中的强度变化及对比剂的空间分布，提升 NCCT 图像中肺栓塞的分割精度。实验结果表明，该方法在减少对比剂使用的同时，仍保持良好的诊断性能。

（3）胸部结构自动分割系统：针对 CT 图像，设计了一种自动分割五大胸部器官（骨头、肺野、心脏、肺动脉、气道）及肺栓塞病变的系统，帮助医生快速、准确地识别胸部结构，提高诊疗效率。

本文通过详尽的对比实验和消融实验，验证了所提出方法的可行性和有效性。实验结果表明，所提出的方法在肺栓塞分割任务中优于现有技术，为深度学习在医学影像分析中的应用提供了有价值的参考。

关键字：肺栓塞 深度学习 医学图像分割 自监督学习

Research on Deep Learning-Based Segmentation Methods for Pulmonary Artery Embolism in CT Images and Implementation of an Automated Segmentation System

Name: Ruolin Xiao

Supervisor: Prof. Wei Yang

ABSTRACT

Pulmonary embolism (PE) is a clinical syndrome caused by endogenous or exogenous emboli obstructing the pulmonary artery and its branches, which can lead to right heart dysfunction, organ failure, and even death in severe cases. Early diagnosis and timely intervention are crucial for reducing the disability and mortality rates associated with PE. However, the clinical manifestations of PE lack specificity, and the current gold standard for diagnosis relies on CT pulmonary angiography (CTPA), which is time-consuming and susceptible to subjective factors, leading to high rates of missed and misdiagnosis. In recent years, the application of deep learning technology in medical imaging has provided new solutions for the automatic diagnosis of PE.

This thesis focuses on the automatic segmentation of PE, aiming to improve diagnostic efficiency, reduce misdiagnosis rate and provide objective basis for clinical evaluation. The research content mainly includes the following three aspects:

(1) Research on automatic segmentation method of PE based on CTPA images: In view of the limitations of existing methods in PE segmentation, a cross-difficulty perception network for CT diagnosis mode is proposed. The network simulates the collaborative diagnosis mode of multimodal CT images, learns the intensity difference between PE and surrounding tissues, and effectively reduces false positive segmentation, especially when dealing with small size and similar areas between tissues. In addition, the cross-difficulty perception strategy and difficulty perception loss function are introduced to enhance the attention to irregular morphology and variable position areas. Experimental results show that this method is superior to existing technologies in PE segmentation tasks.

(2) Research on automatic segmentation method of PE based on non-contrast computed tomography (NCCT): In view of the risks that contrast agents may cause in CTPA examinations, a NCCT pulmonary embolism segmentation method based on self-supervised learning is proposed. Through the multi-task contrast mask image modeling framework, this method can effectively capture the intensity changes and spatial distribution of contrast agents in the image without contrast agents, and improve the segmentation accuracy of PE in NCCT images. Experimental results show that this method can reduce the use of contrast agents while maintaining good diagnostic performance.

(3) Automatic chest structure segmentation system: For CT images, a method for automatically segmenting five major chest organs (bone, lung field, heart, pulmonary artery, airway) and PE lesions is proposed, and a friendly graphical user interface is developed to help doctors quickly and accurately identify chest structures and improve diagnosis and treatment efficiency.

This thesis verifies the feasibility and effectiveness of the proposed method

through detailed comparative experiments and ablation experiments. Experimental results show that the proposed method is superior to the existing technology in the PE segmentation task, providing a valuable reference for the application of deep learning in medical image analysis.

KEYWORDS: Pulmonary embolism; Deep learning; Medical image segmentation; Self-supervised learning

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 研究现状.....	3
1.2.1 基于 CTPA 图像的肺栓塞检测方法.....	3
1.2.2 基于 CTPA 图像的肺栓塞分割方法.....	5
1.2.3 医学图像合成与分割的多任务学习方法	6
1.2.4 基于医学图像的自监督学习方法研究	7
1.3 本文主要工作.....	8
第二章 基于 CTPA 图像的肺栓塞自动分割方法研究	10
2.1 本章引言.....	10
2.2 数据.....	12
2.2.1 数据集描述.....	12
2.2.2 数据预处理.....	13
2.3 面向 CT 诊断模式和跨难度感知网络的肺栓塞自动分割方法.....	13
2.3.1 问题表述.....	13
2.3.2 整体框架 DMC-Net	15
2.3.3 模型结构.....	17
2.3.4 损失函数.....	18
2.4 实验细节.....	19
2.4.1 实验设置.....	19
2.4.2 评价指标.....	20
2.5 实验结果与分析.....	21
2.5.1 消融实验.....	21
2.5.2 不同分割方法在中心 1 测试集上的性能比较	22
2.5.3 不同分割方法在中心 2 数据上的性能比较	24
2.5.4 不同分割方法在公开数据库 FUMPE 上的性能比较	25
2.5.6 不同分割方法在公开数据库 CAD-PE 上的性能比较	27
2.6 本章讨论与结论.....	28
第三章 基于 NCCT 图像的肺栓塞自动分割方法研究	31
3.1 本章引言.....	31
3.2 数据.....	33
3.2.1 数据集描述.....	33
3.2.2 数据预处理.....	34
3.3 基于多任务对比剂掩码图像建模的肺栓塞自动分割方法	34

3.3.1 问题表述.....	34
3.3.2 整体框架 MCAMIM.....	35
3.3.3 模型结构.....	37
3.4 实验细节.....	37
3.4.1 实验设置.....	37
3.4.2 评价指标.....	38
3.5 实验结果与分析.....	38
3.5.1 消融实验.....	38
3.5.2 不同方法的性能比较.....	40
3.6 本章讨论与结论.....	41
第四章 胸部结构自动分割系统	43
4.1 本章引言.....	43
4.2 目标与需求分析.....	44
4.2.1 目标.....	44
4.2.2 需求分析.....	45
4.3 系统总体设计.....	46
4.4 系统实现.....	46
4.4.1 系统开发环境.....	46
4.4.2 数据集.....	47
4.4.3 基于深度学习的胸部多器官自动分割模型构建	48
4.4.4 胸部多器官边缘自动检测算法设计	52
4.4.5 系统 GUI 设计与开发.....	54
4.5 系统测试.....	57
4.5.1 系统概述.....	57
4.5.2 系统功能测试.....	57
4.6 本章讨论与结论.....	62
第五章 总结与展望	64
5.1 本文工作总结.....	64
5.2 未来工作展望.....	65
参考文献.....	66

第一章 绪论

1.1 研究背景与意义

肺栓塞 (pulmonary embolism, PE) 是由内源性或外源性栓子阻塞肺动脉及其分支, 从而引起肺循环障碍和右心功能受损的一种临床综合征^[1]。肺血栓栓塞是最常见的肺栓塞类型, 主要由静脉系统或右心附壁的血栓阻塞肺动脉及其分支所致。血栓经血液流动穿过右心腔, 当栓子滞留于肺动脉时, 会阻碍血流导致氧交换不良。严重情况下, 氧交换完全中断, 右心室后负荷显著增加。氧合减少会导致重要器官供氧不足, 进而引发器官功能受损甚至衰竭。而右室后负荷增加会导致右心劳损, 引发右心衰竭、缺血乃至死亡。因此, 肺栓塞是一种危及生命的心血管疾病, 其严重程度仅次于急性冠脉综合征和卒中^[2]。最新的国际注册研究显示^[3], 急性肺栓塞患者的 7 天全因病死率为 1.9%至 2.9%, 30 天全因病死率为 4.9%至 6.6%。研究表明^[4], 急性肺栓塞的大多数死亡发生在发病后的几小时至几天内, 其中超过 70%的死亡发生在发病后的第一个小时内。急性肺栓塞若不及时治疗, 其总体死亡率可达到 38%, 且在发病后 14 天内的死亡率高达 11.4%。然而, 通过及时的诊断和有效的治疗干预, 这一比例可显著下降至 10%以下。因此, 早期诊断与及时干预是有效降低肺栓塞致残率和病死率的关键^[5]。

肺栓塞的临床表现和体征缺乏特异性, 通常受到肺动脉堵塞范围、发生速度以及患者基础心肺功能状态等因素的影响。常见症状包括呼吸困难及气促 (80%~90%)、胸膜炎性胸痛 (40%~70%)、晕厥 (11%~20%)、烦躁不安、惊恐甚至濒死感 (15%~55%)、咳嗽 (20%~56%)、咯血 (11%~30%)、心悸 (10%~32%)、低血压和 (或) 休克 (1%~5%)、猝死 (<1%)^[6]。对于伴有基础疾病的患者, 这些症状可能与其他疾病表现类似, 容易被忽视或误诊, 从而大大增加了肺栓塞早期诊断和治疗的难度。

目前，公认的肺栓塞诊断金标准检查是 CT 肺动脉造影（computed tomographic pulmonary arteriography, CTPA）。CTPA 具有无创、图像清晰及扫描速度快等优点，能够直观展示肺栓塞的具体位置、涉及范围、形态体征和病变程度^[7]。CTPA 图像通常由数百个切片组成，肺栓塞在 CTPA 表现为肺动脉内的低密度充盈缺损，即明亮血管腔包围的暗区。这种阻塞性缺损是由于栓子阻塞对比剂流动所致。由于肺栓塞的临床症状缺乏特异性，且目前没有针对肺栓塞的实验室检查手段，人工诊断仍是主要的确诊方式。诊断流程通常包括获取患者的 CTPA 图像，由医生逐层阅片，仔细检查数百层切片中的每条肺动脉，并手动分割出肺栓塞区域。最后根据分割结果评估患者病情的严重程度^[8]。然而，整个人工诊断过程非常耗时，且容易受到医生经验、注意力集中程度以及视觉疲劳等主观因素的影响，导致诊断结果在不同医生之间存在差异^[9]。更重要的是，这种繁琐的人工诊断方法可能导致较高的漏诊率和误诊率。据统计，即使是经验丰富的医生，其误诊率仍然在 6%至 23%之间^[10]。

随着深度学习的快速发展，其在医学影像领域的应用日益广泛，为临床提供了重要的计算机辅助诊断支持。深度学习在医学图像分类^[11]、医学图像分割^[12]和预后预测^[13]等计算机辅助诊断领域都取得了显著成效。基于深度学习的肺栓塞自动分割技术能够高效、准确地识别和分割肺栓塞区域，减少人工阅片的时间和工作量，同时降低因医生主观因素导致的诊断不一致性。此外，肺栓塞的定量分割结果可用于血栓负荷的计算与评估，这一指标在制定个体化治疗策略中具有重要参考价值。在实际诊疗中，血栓负荷作为衡量病情严重程度与评估治疗疗效的核心指标，直接影响治疗策略的选择。当前临床指南推荐^[14]，对于低危肺栓塞患者主要采用抗凝治疗，而对于伴有右心负荷增加或血流动力学不稳定的高危患者，则需考虑更积极的溶栓或介入治疗手段。血栓负荷大小不仅是判断病情严重程度的依据，也是评估治疗前后疗效的关键指标。

基于 CTPA 的肺栓塞自动分割技术在定量评估肺栓塞严重程度方面具有重

要意义。CTPA 作为诊断金标准，能够清晰展示肺动脉充盈缺损情况，提供精确的病变定位和严重程度信息。自动分割技术不仅提高了诊断效率，还能识别人眼难以察觉的微小肺栓塞，进一步提升诊断的敏感性和特异性，减少漏诊和误诊率。然而，CTPA 检查中碘对比剂的使用可能引发过敏反应或肾功能损坏^[15-17]，限制了其在特定患者群体中的应用。非增强 CT（Non-Contrast Computed Tomography, NCCT）作为一种无需对比剂的影像学检查手段，具有高效、便捷、安全性高的特点，尤其适用于无法接受对比剂的患者。基于 NCCT 的肺栓塞分割技术通过深度学习算法，能够提取相关特征并实现栓塞区域的自动识别。基于 CTPA 和 NCCT 的肺栓塞自动分割技术各有其独特的临床意义和应用价值。CTPA 能够提供高精度的诊断信息，而 NCCT 则在降低检查风险、扩大适用人群方面展现出重要潜力。通过应用深度学习算法，建立准确的医学辅助检测模型，将为肺栓塞的早期诊断、精准治疗和预后评估提供更全面的技术支持。

1.2 研究现状

1.2.1 基于 CTPA 图像的肺栓塞检测方法

肺栓塞的自动检测在提高临床诊断准确性和治疗效率方面具有重要意义。传统方法^[18, 19]主要依赖于从 CTPA 图像中提取的手工特征。这些特征不仅包括肺栓塞的强度、形状和大小等基本信息，还涉及肺血管的位置和形态、基于数学形态学的局部对比度、基于二阶导数的曲率特征以及血管的几何特征（如体积和长度）等。然而，尽管这些特征能够提供一定的区分信息，但其表示能力和泛化性较为有限。因此，传统方法通常需要处理大量的假阳性才能达到可接受的灵敏度，而这些假阳性大多数来源于静脉充盈、奇静脉及淋巴组织等非肺栓塞结构的误判^[20]。此外，传统方法的性能往往受到 CTPA 图像质量的影响，运动呼吸伪影、条形伪影、部分容积伪影、血管增强不均、噪声以及伴随的肺部疾

病等因素，都会导致图像质量下降，从而影响肺栓塞检测的准确性和稳定性^[21]。传统方法在特征选择和图像质量处理方面的局限性，限制了其在实际临床环境中的应用效果。

与传统方法相比，深度学习方法在检测肺栓塞中表现出更好的性能，尤其是卷积神经网络（Convolutional Neural Network, CNN）在该领域的应用日益受到关注^[22-24]。例如，Tajbakhsh 等人^[23]提出了一种基于 CNN 的肺栓塞检测方法，该方法利用来自图像分割和血管对齐的预处理特征作为 CNN 框架的输入^[22]。该方法首先识别出潜在的肺栓塞区域，并通过分类器减少假阳性检测，其在肺栓塞分类任务中的灵敏度达到 93%。Long 等人^[24]提出了基于概率分布的 Probability-based Mask R-CNN，通过利用临床先验知识将检测范围缩小到肺栓塞的多发区域而不是整张 CTPA 图像，从而提高检测精度和速度。另一项研究提出了一种两阶段多任务深度学习方法，旨在从 CTPA 图像中自动分类肺栓塞^[25]。该方法首先使用微调后的三维 ResNet-18 模型提取图像的三维特征，随后在第二阶段利用时间卷积网络进一步处理特征并预测与肺栓塞相关的标签。PE DeepNet 模型^[26]则包含两个带有 ReLU 激活函数的二维卷积层，一个最大池化层以及一个独特的 PE DeepNet 模块，最终通过 S 型分类器进行肺栓塞分类。Vainio 等人^[27]采用了另一种基于 CNN 的模型，该模型基于二维最大强度投影图像，首先通过 DenseNet-121 网络进行特征提取，随后将提取的平均特征向量传递至三层分类网络进行肺栓塞检测。此外，在北美放射学会肺栓塞检测挑战数据集中，Islam 等人^[28]的解决方案在切片级别实现了 96.76% 的 AUC，在检查级别实现了 91.35% 的 AUC，表现出优异的分类性能和高效的检测能力。然而，尽管这些深度学习方法在肺栓塞检测中取得了显著进展，但它们大多无法像分割方法一样提供对肺栓塞的全面评估，包括其大小、形态和分布等方面。这种综合评估在衡量肺栓塞病情严重程度和制定治疗策略方面起着至关重要的作用。

1.2.2 基于 CTPA 图像的肺栓塞分割方法

医学图像分割作为计算机辅助诊断的关键任务之一，其目标是通过预测每个体素的语义类别（即特定器官或病变）来实现精确的解剖结构识别。近年来，深度学习方法在医学图像分割领域取得了重大进展，研究者提出了各种创新分割模型以提高分割精度。其中，空间金字塔池化技术通过多尺度特征融合有效提升了特征表达能力^[29]。空洞卷积则通过扩展感受野实现了对细节特征的精准捕捉^[30]。而各类注意力机制的引入增强了模型对关键区域的聚焦能力，进一步提升了分割性能^[31, 32]。

在肺栓塞分割领域，自动分割技术能够定量评估肺栓塞区域内的阻塞程度和血栓负荷，为医生提供精确且全面的诊断信息。然而，由于肺栓塞在形状、大小和位置上的异质性，使得其自动分割成为一项具有挑战性的任务。尽管当前主流的语义分割方法如 nnUNet^[33]、Swin-UNet^[34]和 TransUNet^[35]在多种医学图像分割任务中表现出色，但在处理肺栓塞分割时仍面临诸多挑战，这主要源于肺栓塞的形态不规则和位置多变性。近年来，基于深度学习的计算机辅助诊断方法在肺栓塞分割中取得了一系列进展^[36-38]。其中，图像裁剪技术的应用能够让模型专注于肺动脉内的中央肺栓塞分割^[36]。尽管这种方法能有效聚焦肺栓塞，但单独优化中央肺栓塞分割存在一定局限性。目前，自动分割仍面临假阳性率高的问题，即非肺栓塞区域被错误地识别为肺栓塞。为了减少误识率，最近的研究开始结合血管分割技术以提高定位准确性^[39, 40]。例如，Guo 等人^[39]创新地利用动脉信息作为先验知识，同时分割肺动脉和肺栓塞，从而排除可疑的肺栓塞区域。值得注意的是，这些方法的性能在很大程度上依赖于血管分割的准确性。为减少对血管注释数据的依赖，有研究^[41]尝试通过模型集成技术提高整体性能。针对肺栓塞尺寸小导致的高错误率问题，研究者们提出了多种解决方案。例如，通过肺动脉裁剪技术或引入类别不平衡损失来增强对肺栓塞区域的关注^[37, 42]。

然而，这些基于动脉信息或裁剪动脉区域的方法通常依赖于手工标注的肺动脉标签，导致时间和人力成本较高。为进一步提高对肺栓塞区域的识别，Wen 等人^[42]提出了结合 Dice 损失和 Focal 损失的混合损失函数，有效缓解了极端的类别不平衡问题。现有方法通常将肺栓塞视为具有一致分割难度的区域，但实际上，其形状和位置的多变性大大增加了分割难度，特别是在形状极其不规则的区域。为了解决这个问题，研究者们提出了多种边界优化方法来提高边界分割精度^[43-45]。考虑到单一模型在处理复杂分割任务时的固有局限性，一些方法提出了双路径架构，通过引入辅助路径来细化细节和边界信息^[46, 47]。

1.2.3 医学图像合成与分割的多任务学习方法

生成对抗网络（Generative Adversarial Network, GAN）的快速发展推动了医学图像合成的广泛研究，包括缺失磁共振成像（Magnetic Resonance Imaging, MRI）合成^[48-50]、多对比度 CT 图像合成^[51-53]以及 MRI 和 CT 的跨模态合成^[54]。Zhang 等人^[55]通过同时考虑真实 CT 和合成 CT 之间的像素间相关性和图像内相关性，成功增强了图像对比度并提高了器官边缘清晰度。虽然这些方法在生成视觉上可信的图像方面取得了显著效果，但它们无法保证合成图像包含对鉴别诊断至关重要的病理信息。医学图像合成作为一种有效的策略，能够整合跨模态的互补信息，消除多模态配准误差，并在特定模态信息缺失时提供重要补充信息^[53, 56, 57]。例如，Zhang 等人^[57]通过融合 MRI 的软组织分辨率和 CT 的电子密度信息，实现了器官和危及器官的精确分割任务。在辅助 CT 图像分割任务中，医学图像合成技术通过提供器官或病变与周围组织间的强度差异信息，从而提升分割精度^[58-60]。近年来，研究者们探索了基于深度学习的合成和分割多任务框架^[57, 61-65]。例如，RS-Net^[62]采用并行结构，通过共享潜在表示空间，实现了缺失 MRI 的生成和肿瘤区域的同步分割，使得网络能够专注于肿瘤区域的精确合成与分割。但是这些方法忽视了合成任务反馈对分割过程的重要作用。为此，Zhang

等人^[55]提出了一种级联框架，通过引入跨任务反馈机制，将分割信息反馈给合成网络，从而优化合成图像的轮廓细节。

1.2.4 基于医学图像的自监督学习方法研究

CTPA 因其高空间分辨率和血管结构显示能力，已成为肺栓塞诊断的临床金标准。但其使用碘对比剂的特性带来了潜在的临床风险。研究表明，对比剂可能诱发一系列不良反应，包括造成肾损伤^[15]、急性碘过敏反应^[16]以及过敏性休克^[17]等，这些并发症不仅增加了患者的治疗风险，也可能影响诊断流程的顺利进行。因此，如何在降低对比剂使用的同时保持足够的诊断敏感性，已成为医学图像领域的重要研究方向。NCCT 无需对比剂，且能够提供丰富的解剖结构信息，适用于无法接受对比剂的患者。通过探索基于 NCCT 的肺栓塞分割技术，结合深度学习算法，能够提取相关特征并实现栓塞区域的自动识别。在涉及非增强图像的病变识别任务中，监督学习方法通常采用迁移学习策略，即从增强图像中提取病变相关特征，并将其迁移到非增强图像上以提升检测性能^[66, 67]。然而，这些方法存在着局限性，首先，其性能高度依赖于标注数据来指导模型训练。其次，标注数据的稀缺性会限制模型在大规模数据上的可扩展性和泛化能力。

相比之下，自监督学习方法通过设计预训练任务，从大规模未标注数据中学习有效的特征表示，降低了对数据标注的依赖，为医学图像分析提供了新的解决方案。自监督学习在医学图像分析领域的应用已取得很大的进展，广泛应用于医学图像合成与分割任务，如血管分割^[68]、COVID-19 图像分割^[69]以及超声到 MRI 的跨模态合成^[70]。例如，Ma 等人^[71]提出了一种基于对抗学习的自监督框架，通过从未标注的冠状动脉造影图像中学习血管的形态和结构特征，实现了高质量的血管分割。这一方法不仅减少了对标注数据的依赖，还提高了模型在复杂血管结构中的分割精度。近年来，掩码图像建模（Masked Image Modeling,

MIM) 在医学图像自监督预训练中展现出巨大潜力。MIM 通过随机掩码部分图像区域并训练模型重建被掩码的内容, 使得模型能够学习到更丰富的图像特征和上下文信息。在设计预训练任务时, 研究者们关注如何捕捉医学图像中特定的病理特征, 以及如何将自监督学习与领域知识相结合以提升模型的临床适用性。研究者们通过将基于 MIM 的自监督预训练方法应用于包括 CT 图像和超声等医学图像的分析, 以促进下游任务的分析^[72-74]。例如, Kang 等人^[74]针对超声图像的特性, 创新性地将超声图像去模糊任务作为预训练代理任务之一, 通过优化模型对模糊超声图像的重建能力, 提高模型对图像细节的捕获能力, 改善了下游超声图像分析任务的性能。

1.3 本文主要工作

为了有效辅助临床医生进行肺栓塞诊断, 本文提出了新的自动分割方法。实验结果表明, 所提出的方法在目标数据集上实现了较高水平的分割性能。当前, 深度学习在肺栓塞分割领域面临着一系列挑战: 首先是数据集不足的问题, 深度学习模型对大规模标注数据的需求较高, 由于医学数据标注成本高昂、依赖于专业知识且耗时, 通常缺乏足够的标注数据来训练分割模型, 这使得三维医学图像分割任务变得更具挑战性^[75, 76]。其次是肺栓塞尺寸小、形态和位置多变, 使得深度学习模型在分割此类目标时表现受限。以及多模态信息整合的不足, 现有方法在多模态信息的有效整合仍是肺栓塞分割中的一个难题。

本文的组织结构如下:

第一章是绪论。本章在系统梳理国内外相关文献的基础上, 首先阐述了肺栓塞的医学背景和肺栓塞自动分割的临床意义, 随后总结了肺栓塞自动分类、目标检测和分割技术的研究进展, 最后概述了本文的主要研究内容及创新点。

第二章是基于 CTPA 图像的肺栓塞分割方法研究。本章提出了一种面向 CT 诊断模式的交叉难度感知网络, 用于肺栓塞的自动分割。该网络通过模拟多模态 CT 图像协作诊断模式, 学习肺栓塞与周围组织之间的强度差异, 从而有效减

少假阳性分割，特别在处理小尺寸及组织间相似区域时表现突出。此外，本方法引入了交叉难度感知策略，并设计了难度感知损失函数，以增强对肺栓塞形态不规则和位置变化引发的困难分割区域的关注。最后，介绍了实验所用的数据集和实验细节，并总结了相关对比实验和消融实验的结果，验证了该模型的可行性和有效性。

第三章是基于 NCCT 图像的肺栓塞分割方法研究。本章是在第二章工作的基础上，针对无对比增强图像场景的延伸研究，第二章基于 CTPA 图像构建肺栓塞分割模型，侧重探索对比增强信息对病灶识别的价值，然而实际临床中部分患者会有对比剂禁忌或资源限制，获取 CTPA 图像的难度较大。因此，本章旨在探索在无对比剂条件下如何仍保持较高的分割性能，本章提出了一种多任务对比剂掩码图像建模框架，通过自监督学习提升 NCCT 图像中肺栓塞的分割精度。通过自监督学习的对比剂表示学习，该方法能够有效捕捉图像中的强度变化及对比剂的空间分布。为了进一步提高肺栓塞与周围组织的区分度，本章还引入了联合合成和分割的多任务学习策略，通过共享关键视觉信息，提升了模型对重要特征的捕捉能力。本章所提出的方法为基于 NCCT 图像的肺栓塞分割提供了一种创新性解决方案，能够在无需对比剂的情况下，仍保持良好的诊断性能。

第四章介绍了胸部多器官结构自动分割识别系统，是在前两章基础上的系统集成与拓展。该系统能够从 CT 图像中自动分割并识别骨头、肺野、心脏、肺动脉、气道等五大器官及肺栓塞病变，为临床诊断和治疗提供支持。本章设计并开发了友好高效的图形用户界面，帮助医生快速准确地识别胸部结构，提高诊疗效率和准确性。

第五章是总结和展望。本章系统总结了本研究的主要工作，并针对工作中存在的不足，提出和探讨了未来可能的研究方向。

第二章 基于 CTPA 图像的肺栓塞自动分割方法研究

2.1 本章引言

CTPA 中的肺栓塞自动分割在定量评估肺栓塞严重程度方面具有重要意义，有助于提高诊断的准确性和全面性。尽管已经有许多研究致力于开发计算机辅助诊断系统以实现肺栓塞的自动诊断^[10, 28, 77, 78]，但这些研究主要集中在定性分析上，缺乏肺栓塞严重程度进行定量评估的能力。自动肺栓塞分割可以定量评估阻塞程度和血栓负荷，为医生提供更精确而全面的诊断信息。

近年来，基于深度学习的肺栓塞自动分割取得了新进展，研究者们提出了多种新方法^[36-38]。其中，一种方法通过图像裁剪集中分割主肺动脉内的中央肺栓塞^[36]。然而，由于单独优化中央肺栓塞分割存在局限性，研究重点转向更精细的方法，通过整合血管分割技术来更精确地定位肺栓塞^[39, 40]。值得注意的是，这些方法的血管分割准确性直接或间接影响肺栓塞分割的准确性。为了减少对血管注释数据的依赖，最近的一项研究^[41]尝试通过模型集成技术提高整体性能。然而，当前的分割仍然面临挑战，特别是在假阳性率方面，非肺栓塞区域被错误地识别为肺栓塞（如图 2-1 (a)所示）。肺栓塞的小尺寸及其与周围组织的相似性对分割任务提出了重大挑战（如图 2-1 (a)~(b)所示）。不同 CT 模态之间的对比度差异成为解决这一挑战的关键因素，为器官或病变分割提供强有力的支持^[58-60, 79]。在临床实践中，当医生在 CTPA 中遇到疑似但不确定的肺栓塞病例时，NCCT 可以提供组织密度信息。肺栓塞通常在 CTPA 上表现为充盈缺损^[80]。NCCT 可以通过提供解剖细节、特征性特征以及与肺栓塞异常相关的周围结构信息来协助评估这种充盈缺损。结合 NCCT 和 CTPA 的诊断优势，可以帮助医生区分肺栓塞特征，从而降低由肺栓塞的小尺寸和组织间相似性引起的假阳性率。然而，额外的 NCCT 扫描会增加电离辐射和患者费用。因此，开发一个可以模仿 CT 诊断模式的模块可能有助于提高自动肺栓塞分割的性能。




图 2-1 CTPA 上分割肺栓塞的主要挑战。绿色表示现有方法的分割结果，红色表示标签。

Fig. 2-1 The main challenges in segmenting pulmonary embolism on CTPA images.

Green represents the segmentation results of existing methods, and red represents the labels.

虽然 nnUNet^[44]、Swin-UNet^[44]和 TransUNet^[35]等语义分割方法在许多医学图像分割任务中表现出色，但它们在应用于肺栓塞分割时仍面临挑战，主要是由于肺栓塞形状不规则且位置多变（如图 2-1 (c)所示）。为了增强对肺栓塞区域的关注，Wen 等人^[42]结合 Dice 损失和 Focal 损失函数来解决极端的类别不平衡问题。这些方法通常将肺栓塞视为具有一致分割难度的区域。然而，肺栓塞形状和位置的多变性大大增加了分割难度，特别是在形状极其不规则的区域。为了解决这一问题，研究人员提出了多种方法来提高边界分割精度^[43-45]。考虑到单一模型在处理这种复杂性时的固有偏差和局限性，一些方法提出了双路径方法，通过引入路径辅助细化方法来捕获细节和边界信息^[16, 47]。然而，这些方法对不同路径的分割结果采用特征融合或简单的加权平均，可能会忽略不同路径的差异信息。最小化困难区域中不同路径之间的差异可能是有效缓解由于单一模型

固有偏差而导致的分割误差的有效策略。

在本章中引入了一种面向 CT 诊断模式和跨难度感知网络 (CT diagnostic mode-oriented and cross difficulty-aware network, DMCD-Net) 用于肺栓塞分割 (如图 2-2 所示)。本章假设模仿 NCCT 和 CTPA 图像的协同诊断模式可以引导网络关注肺栓塞和肺动脉区域, 从而提高肺栓塞分割的性能。为了减少由于肺栓塞尺寸小和组织间相似性而导致的假阳性, 本章提出了一个面向 CT 诊断模式的模块 (CT diagnostic mode-oriented module, CT-DM), 利用医学图像合成来学习肺栓塞与周围组织之间的多模态 CT 强度差异。此外, 为了解决由于形状不规则和位置变化导致的分割性能一般的问题, 本章引入了一种交叉难度感知分割方案 (cross difficulty-aware segmentation scheme, CDS), 该方案采用交叉监督策略和难度感知损失函数来处理由肺栓塞的不规则形状和位置变化引起的分割错误。

2.2 数据

2.2.1 数据集描述

为了评估所提出的 DMCD-Net 模型, 本章采用了两个多中心数据集和两个公共数据集进行实验。具体而言, 两个多中心数据集分别来自珠江医院 (中心 1) 和仁济医院 (中心 2), 而公共数据集则包括 FUMPE 数据集^[81]和 CAD-PE 挑战数据集^[82]。中心 1 的数据集包含 99 名肺栓塞患者的 NCCT、CTPA 图像及对应的肺栓塞标签; 中心 2 的数据集则包含 6 名患者的 NCCT、CTPA 图像及其相应的肺栓塞标签。FUMPE 数据集包含 32 例 CTPA 图像, 其中排除了 2 例无栓塞病例和 1 例图像质量不合格的病例。CAD-PE 挑战数据集包含 91 张 CTPA 图像。为确保模型训练和评估的可靠性, 中心 1 的数据集被随机分为训练集和测试集, 训练集包含 85 例样本, 测试集包含 14 例样本。为了进一步验证模型的泛化能力, 模型评估还包括了中心 2 的数据集、FUMPE 数据集、CAD-PE 挑战数据集

以及中心 1 的独立测试集。通过在不同来源和多样性的数据集上进行全面评估，确保了模型在多中心、多样本环境中的泛化性能。出于对患者隐私的保护，所有医学图像在使用前均已按照伦理与信息安全要求进行规范化脱敏处理，去除了患者姓名、身份证号、检查时间、机构编号等所有可能识别个体身份的信息。数据的获取与使用严格依据研究单位的内部数据安全协议，并在权限受控、物理隔离的环境下完成，确保研究过程中的数据隐私与合规性。

2.2.2 数据预处理

在图像预处理阶段，为了确保图像空间的一致性，实验首先采用 FSL 工具进行仿射空间归一化，将不同扫描条件下的 CT 图像映射到统一的空间中。随后，利用 ANTS 软件进行对称归一化，进一步优化了图像的对齐精度，尤其是在中心 1 中的 NCCT 和 CECT 图像的配准过程中，确保了跨模态图像的空间一致性。这一系列的空间标准化操作为后续的深度学习模型训练提供了规范化的图像数据，减少了由于空间变形和配准误差导致的影响。鉴于 CT 图像中的亨斯菲尔德单位值范围较为广泛，因此，实验采用了分段最小最大归一化方法，以有效突出目标区域的特征。所有 CT 图像均在 $[-1, 1]$ 的标准化范围内进行线性归一化，确保了输入数据的统一尺度，有助于提升模型训练的稳定性。此外，为进一步提升分割模型的性能，还引入了阈值化和孔填充技术进行去床处理。通过阈值化方法，图像中的非目标区域被有效过滤，保留了关键的结构信息，从而减少了背景噪声的干扰。孔填充技术则用于填补图像中的空洞，确保了生成的掩模连通性和完整性，后续分割任务提供了更精确的图像掩模。

2.3 面向 CT 诊断模式和跨难度感知网络的肺栓塞自动分割方法

2.3.1 问题表述

本章提出的用于 CTPA 图像肺栓塞分割的 DMCD-Net 架构如图 2-2 所示。DMCD-Net 旨在应对肺栓塞分割中的关键挑战，主要包括肺栓塞尺寸小、组织间高度相似性、以及肺栓塞形态的不规则性和位置的多变性。其目标是开发一个高效的自动分割模型，能够在 CTPA 图像中准确地分割出肺栓塞区域。设数据集 $\mathbb{D} = (A_i, Y_i)_{i=1}^n$ ，其中 $A_i \in \mathbb{R}^{D \cdot H \cdot W \cdot 1}$ 表示 CTPA 图像集， $Y_i \in \mathbb{R}^K$ 则为相应的肺栓塞标签。分割模型的目标是通过训练学习函数 $\hat{Y} = \mathbf{M}(A)$ ，即从输入的 CTPA 图像中准确预测出肺栓塞。现有的肺栓塞分割模型 $\mathbf{M}$ 仍面临较大的挑战，特别是在肺栓塞的尺寸极小且与周围组织相似的情况下，现有方法往往会产生较高的假阳性率。这些模型通常将肺栓塞区域的分割难度视为一样，忽视了肺栓塞的形状不规则性和在图像中的位置变化所带来的额外挑战。为了解决这些问题，本章提出了 DMCD-Net 架构，该模型融合了模拟 CT 诊断模式和交叉难度感知损失函数，从而能够更有效地识别并分割肺栓塞区域。DMCD-Net 的工作原理及其创新性细节将在后续章节中进行详细讨论和分析。




图 2-2 DMCD-Net 总体架构示意图。

Fig.2-2 Schematic diagram of the overall architecture of DMCD-Net.

2.3.2 整体框架 DMCD-Net

DMCD-Net 主要由 CT-DM 模块和 CDS 方案组成，CT-DM 模块用于模拟 NCCT 和 CTPA 图像的协同诊断模式，CDS 方案用于解决由于肺栓塞形状不规则和位置多变而引起的分割错误。

2.3.2.1 CT-DM

肺栓塞在 CTPA 上表现为充盈缺损，而 NCCT 通过提供与肺栓塞异常相关的解剖细节、特征和周围结构信息来协助评估这种充盈缺损。这些全面的信息有助于排除软组织或静脉内的可疑肺栓塞，从而降低假阳性率。因此，本章提出了一个 CT-DM 模块，它模仿协同诊断过程（如图 2-2 (a)所示）。该模块使用 NCCT 到 CTPA 和 NCCT 到 NCCT 的合成来学习肺栓塞与周围组织之间的多模态 CT 强度差异。

理想情况下，NCCT 和 CTPA 之间的差异主要在于肺栓塞和血管增强，而其它解剖结构保持不变。如果 CTPA 图像可以有效地分离为解剖结构和对比剂成分，则可以根据解剖结构轻松检测出异常。这种方法有助于模型在从 NCCT 合成 CTPA 期间学习肺栓塞的增强模式，从而将其与由于增强模式不同而容易与肺栓塞混淆的组织区分开来。给定一对 CTPA 图像 A 和 NCCT 图像 $B \in \mathbb{R}^{D \times H \times W \times 1}$ ，本章利用共享编码器 E 将它们从图像域映射到潜在空间，然后使用生成器 G_1 和 G_2 将潜在特征重新映射回图像域。在本章的 CT-DM 中，如图 2-2 (a)所示，共享编码器 E 将 CTPA 图像编码到解剖结构和对比剂空间中，并将 NCCT 图像编码到解剖结构空间中。共享潜在空间表示为：

$$\{(f_A^a, f_A^c) = E(A) \quad f_B^a = E(B)\} \quad (2.1)$$

其中 f_A^a 和 f_B^a 表示解剖空间中的解剖特征, f_A^c 是对比剂空间中的对比剂特征。利用这些特征, 生成器可以有效地使用不同的组件来合成 NCCT 或 CTPA 图像。具体来说, 生成器将解剖特征 f_A^a 或 f_B^a 与对比剂特征 f_A^c 相结合来合成 CTPA 图像。

生成器 G_1 使用解剖特征转换 f_A^a 或 f_B^a 生成 NCCT 图像。这些过程可以表示

$$\begin{aligned} \{ \hat{B}^{A \rightarrow B} = G_1(f_A^a), \hat{B}^{B \rightarrow B} = G_1(f_B^a), \\ \hat{A}^{A \rightarrow A} = G_2(f_A^a, f_A^c), \hat{A}^{B \rightarrow A} = G_2(f_B^a, f_A^c) \} \end{aligned} \quad (2.2)$$

当提供 CTPA 图像时, 可以通过 E 和 G_1 获得相应的 NCCT 图像:

$$\hat{B} = G_1(E(A)). \quad (2.3)$$

NCCT 和 CTPA 图像之间增强的差异可以引导模型关注肺栓塞和血管区域, 这有利于消除位于非血管区域的类似组织间结构的干扰。

2.3.2.2 CDS

由于肺栓塞形状不规则、位置多变, 现有分割方法的分割性能差异尤为明显, 导致分割误差程度不一。认识到这种差异与各个模型在处理形状极其不规则的区域时的固有偏差有关, 本章引入了一种 CDS 方案来提高困难区域分割的性能。本章的 CDS 方案利用双分割解码器进行交叉监督。为了构建高效的双分割解码器, 本章利用指数移动平均 (Exponential Moving Average, EMA) 策略^[83]来提高模型的鲁棒性。具体而言, 本章采用 EMA 使用预先训练的分割解码器 S_2 来更新分割解码器 S_1 的参数。输入 A 经 E 编码后, 经过 S_1 和 S_2 分别处理, 获得分割置信度图:

$$P_1 = S_1(E(A)), P_2 = S_2(E(A)), \quad (2.4)$$

其中 $P_1, P_2 \in \mathbb{R}^{D \times H \times W \times 1}$ 表示经 sigmoid 函数归一化的输出。分割标签图 Y_2 可以通过 S_2 独热编码从分割置信度图 P_2 生成:

$$Y_1 = T(P_1), Y_2 = T(P_2) \quad (2.5)$$

其中 $Y_1, Y_2 \in \mathbb{R}^{D \times H \times W \times 2}$ 。 Y_1 监督提示 S_2 与 P_2 具有高相似性, 反之亦然。通过这种交叉监督训练策略, 本章提出的 CDS 让模型关注困难的分割区域。

2.3.3 模型结构

在 DMCD-Net 架构中, 编码器由两个主要分支组成: 一个卷积分支, 用于提取关键的局部特征信息; 一个 Transformer 分支, 旨在捕捉图像的全局语义信息。卷积分支包括四个卷积 INReLU 层, 通道数分别为 16、32、64 和 128。第一层采用 3D 卷积, 内核大小为 (3, 5, 5)。随后的三层卷积均使用相同的内核大小 (3,3,3), 但步幅设置有所不同, 分别为 (2, 2, 2)、(1, 2, 2) 和 (1, 2, 2), 以逐步提取不同尺度的局部特征。Transformer 分支则由三个不重叠的卷积 token 嵌入和相应的 Swin Transformer 块(其嵌入维度分别为 32、64 和 128)组成。卷积 token 嵌入用于提取不重叠的图像块, 其中每个卷积层的内核大小为 (3, 3, 3)、(3, 3, 3)、(3, 3, 3), 步幅分别调整为 (1, 2, 2)、(2, 4, 4) 和 (4, 8, 8), 以增强不同空间尺度上的信息表达。卷积层和 Transformer 层的输出特征图在通道维度上进行连接, 并随后经过卷积操作以进一步融合信息。

在 DMCD-Net 的 CT-DM 和 CDS 模块中, 共享相同的编码器架构。具体而言, CT-DM 模块中的每个生成器包含六个 Swin Transformer 块, 旨在优化全局上下文信息和局部细节特征的融合。此外, 生成器还包括三个上采样卷积 IN-ReLU 层(通道数分别为 64、32 和 16) 以及一个卷积层(通道数为 1)。这

些上采样卷积层在卷积操作之前，分别采用最近邻插值的上采样方式，比例为 (2, 2, 2)、(1, 2, 2) 和 (1, 2, 2)，以逐步恢复图像分辨率。在 CDS 模块中，每个分割解码器的架构与 CT-DM 模块中的生成器结构相同。

2.3.4 损失函数

本章的 DMCD-Net 主要由 CT 诊断模式导向损失和交叉难度感知损失组成。

$$\mathcal{L}_{DMCD} = \mathcal{L}_{CTDM} + \mathcal{L}_{CDS} \quad (2.6)$$

(1) CT 诊断模式导向损失：为了减少由于肺栓塞尺寸小和组织间相似性而导致的假阳性，本章引入了 CT 诊断模式导向损失 $\mathcal{L}_{CTDM}$ ，以便更了解肺栓塞与周围组织之间的多模态 CT 强度差异。 $\mathcal{L}_{CTDM}$ 主要包括两个对抗性损失 $\mathcal{L}_{adv}^A$ 和 $\mathcal{L}_{adv}^B$ 、解剖损失 $\mathcal{L}_a$ 和对比增强损失 $\mathcal{L}_c$ ：

$$\mathcal{L}_{CTDM} = \mathcal{L}_{adv}^A + \mathcal{L}_{adv}^B + \lambda_a \mathcal{L}_a + \lambda_c \mathcal{L}_c \quad (2.7)$$

其中 λ_a 和 λ_c 是超参数。两个对抗性损失 $\mathcal{L}_{adv}^A$ 和 $\mathcal{L}_{adv}^B$ 可以表示为

$$\begin{aligned} \left\{ \mathcal{L}_{adv}^A = \mathbb{E}[\log \mathbf{Dis}_A(A)] + \mathbb{E}[\log(1 - \mathbf{Dis}_A(\hat{A}^{B \rightarrow A}))], \right. \\ \left. \mathcal{L}_{adv}^B = \mathbb{E}[\log \mathbf{Dis}_B(B)] + \mathbb{E}[\log(1 - \mathbf{Dis}_B(\hat{B}^{A \rightarrow B}))]. \right\} \end{aligned} \quad (2.8)$$

由于共享对比增强特征，合成 CTPA 图像和真实 CTPA 图像应具有一致的增强强度。因此，采用对比增强损失来促进对比增强特征的学习：

$$\begin{aligned} \mathcal{L}_c = & \left\| (A - \hat{B}^{A \rightarrow B}) - (\hat{A}^{B \rightarrow A} - B) \right\|_1 + \|A^{A \rightarrow A} - A\|_1 \\ & + \|A^{B \rightarrow A} - A\|_1 + \|A^{A \rightarrow A} - \hat{A}^{B \rightarrow A}\|_1, \end{aligned} \quad (2.9)$$

对于合成和真实的 NCCT 图像，它们的解剖结构表现出一致性。因此，解剖损失 $\mathcal{L}_a$ 可以表示为

$$\mathcal{L}_a = \|B^{A \rightarrow B} - B\|_1. \quad (2.10)$$

(2) 交叉难度感知分割损失:

交叉难度感知分割损失 $\mathcal{L}_{CDS}$ 主要是为了解决肺栓塞分割中严重的类别不平衡以及形状不规则和位置变化带来的难度增加所带来的挑战。

如图 2-2 (c)所示, 本章应用双向监督, 通过 P_2 进行监督 Y_1 , 确保它们之间的高度相似性, 反之亦然。此外, Y_1 和 Y_2 相互监督。通过相互差异监督损失 $\mathcal{L}_{MDS}$, 本章的 CDS 实现了两个分割输出之间的高度相似性, 从而减少了困难区域的分割差异。

$$\mathcal{L}_{MDS} = \|Y_1 - P_2\|_1 + \|Y_2 - P_1\|_1 + \|P_1 - P_2\|_1, \quad (2.11)$$

此外, 为了确保监督信息的有效性, 本章利用难度感知特定损失 $\mathcal{L}_{DAS}$ 来利用分割结果与 GT 之间的差异, 使 CDS 能够捕获更准确的细节和边界信息。

$$\mathcal{L}_{DAS} = \|Y - P_1\|_1 + \|Y - P_2\|_1, \quad (2.12)$$

交叉难度感知损失 $\mathcal{L}_{CDA}$:

$$\begin{aligned} \mathcal{L}_{CDA} = & \mathcal{L}_{MDS} + \mathcal{L}_{DAS} + \mathcal{L}_{CE}(P_1, Y) + \mathcal{L}_{CE}(P_2, Y) \\ & + \mathcal{L}_{Dice}(P_1, Y) + \mathcal{L}_{Dice}(P_2, Y). \end{aligned} \quad (2.13)$$

2.4 实验细节

2.4.1 实验设置

在本实验中, 模型的输入大小设置为 $256 \times 256 \times 8$, 以确保图像数据能够充分利用计算资源并保持较高的分辨率。为了增加训练数据的多样性并提高模型的泛化能力, 采用了数据增强技术, 包括随机平移和翻转操作。在模型训练过程中, 采用 Adam 优化器, 并结合 poly decay 策略调整学习率, 最大迭代次数设

定为 150 次。初始学习率设置为 2×10^{-4} ，并根据 poly decay 策略动态调整，以确保在训练过程中逐渐减少学习率，从而提高训练的稳定性和收敛效果。批次大小设为 2，以平衡计算效率和内存使用，确保每次迭代能够充分利用 GPU 的计算能力。所有实验均在 Pytorch 平台上实现，训练过程中使用具有 11GB 显存的 NVIDIA RTX 2080Ti GPU 进行加速。这一硬件配置能够有效支持大规模图像数据的处理，并确保模型训练的高效性和稳定性。

2.4.2 评价指标

为了定量评估不同方法在肺栓塞分割任务中的性能，实验使用了五个常用的评价指标：Dice 相似系数（Dice Similarity Coefficient, DSC）、Jaccard 相似指数（Jaccard）、敏感性（Sensitivity）以及边界交并比（Boundary Intersection over Union, BIoU）^[43]。这些指标能够从多个角度全面反映分割结果的质量，具体描述如下：DSC 定义为预测结果与真实标签交集的两倍除以其面积之和。用于评估预测结果与真实标签之间的相似性，DSC 可以反映分割结果的整体一致性。Jaccard 定义为预测结果与真实标签交集在两者并集中的比例。用于评估预测结果与真实标签之间的相似程度，强调对误差的敏感性。Sensitivity 衡量了分割模型对肺栓塞区域（真实阳性样本）的识别能力。BIoU 评估了分割边界的精确度，尤其适用于肺栓塞这种形状复杂、不规则的病变区域的分割任务。

此外，为了评估图像合成性能，使用了三个常用的合成评估指标：平均绝对误差（Mean Absolute Error, MAE）：用于度量预测图像与真实图像之间的平均误差，反映了合成图像的整体质量。峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）：通过比较合成图像与原始图像之间的峰值误差来量化图像的质量。结构相似性指数（Structural Similarity Index Measure, SSIM）：从亮度、对比度和结构三个方面评估图像的感知质量，是一种更接近人类视觉认知的评估方法。

2.5 实验结果与分析

2.5.1 消融实验

为了验证 DMCD-Net 中各个模块的贡献，进行了一系列实验，评估不同模块对肺栓塞分割性能的提升作用。具体来说，为了评估双分割解码器是否能够改善肺栓塞的分割效果，设计了一项基线实验，该实验仅使用单个分割编码器进行训练。如表 2-1 所示，加入双分割解码器（Baseline+dual-S）后，模型在多个指标上均取得了提升，其中 DSC 提高了 2.26%，Jaccard 提高了 3.27%，BIOU 提高了 2.65%。在基线模型的基础上加入 CT-DM 模块，模型的性能得到了更大幅度地提升。具体而言，DSC 由 69.94%提升至 72.20%，Jaccard 由 55.51%提升至 58.28%，而 BIOU 则由 55.13%提升至 58.06%。这些结果表明，双分割解码器和 CT-DM 模块在提高肺栓塞分割性能方面具有重要的集体效益。此外，为了评估 DMCD-Net 在图像合成任务中的表现，对其在 CTPA 到 NCCT 图像合成任务中的性能进行了评估。如图 2-3 所示，DMCD-Net 在此任务中展示了出色的合成性能，具体表现为 MAE 为 36.72，SSIM 为 0.848，PSNR 为 30.52。进一步地，DMCD-Net 在重建 CTPA 图像时的性能表现也较好，MAE 为 7.56，SSIM 为 0.989，PSNR 为 39.57。

表 2-1 不同模块上的消融实验结果（%）。

Table 2-1 Ablation experiment results on different modules (%).

模型	DSC	Jaccard	BIOU
Baseline	66.41	51.73	51.66
Baseline+dual-S	67.91	53.42	53.03
Baseline+dual-S+ $\mathcal{L}_{MDS}$	68.96	54.62	54.36
Baseline+dual-S+ $\mathcal{L}_{MDS}+\mathcal{L}_{DAS}$	<u>69.94</u>	<u>55.51</u>	<u>55.13</u>
Ours	72.20	58.28	58.06




图 2-3 在中心 1 上进行合成的 MAE、PSNR 和 SSIM 的箱线图。

Fig.2-3 Box plots of MAE, PSNR, and SSIM synthesized on Center 1.

2.5.2 不同分割方法在中心 1 测试集上的性能比较

为了评估 DMCD-Net 在医学图像分割中的表现，将其与多种性能优异的深度学习分割方法进行了全面比较。所比较的模型包括 UNet，UNet++^[84]，ResUNet++^[85]，AttU-Net^[31]，CPFNet^[86]，Swin-UNet^[34]和 TransUNet^[35]。此外，本章将比较范围扩大到 nnUNet 以及专为肺栓塞分割设计的 SCUNet ++。所有实验均在相同的环境中进行，并采用一致的数据增强方法，确保各方法的公平比较。

如表 2-2 所示，与 UNet 相比，DMCD-Net 在多个关键性能指标上均取得了提升。具体而言，DMCD-Net 在 DSC、Jaccard、Sensitivity 和 BIoU 方面分别提高了 17.45%、26.78%、53.00%和 26.25%。与 nnUNet 相比，DMCD-Net 在 DSC、Jaccard、Sensitivity 和 BIoU 的提升分别达到了 5.94%、10.23%、3.39%和 10.25%。从表 2-2 的数据可以看出，DMCD-Net 在所有比较方法中均取得了最好的性能。

表 2-2 在中心 1 上与其他分割模型的比较结果（%）。

Table 2-2 Comparison results with other segmentation models on center 1 (%).

方法	DSC	Jaccard	Sensitivity	BloU
UNet	61.49	45.97	50.98	45.99
UNet++	66.75	51.31	56.96	51.35
ResUNet++	63.78	48.51	53.97	48.51
AttU-Net	65.07	50.12	55.96	50.14
CPFNet	65.66	50.25	56.66	50.29
Swin-UNet	67.06	52.00	62.48	52.02
TransUNet	65.99	50.45	55.69	50.45
SCUNet++	66.58	51.56	57.09	51.55
nnUNet	<u>68.17</u>	<u>52.87</u>	<u>75.44</u>	<u>52.66</u>
Ours	72.22	58.28	78.00	58.06

图 2-4 展示了不同 SOTA 方法在肺栓塞分割任务中的视觉结果。可以看到，当肺栓塞位于中央大动脉（如第 3 行所示）或呈现较为规则的形态（如第 4 行所示）时，所有比较方法的分割效果都能够满足基本要求。然而，当肺栓塞位于较小的动脉中，或其形状较为复杂（如第 1 行和第 2 行所示）时，大部分方法的分割性能显著下降。在这些挑战性较高的情形下，DMCD-Net 展示了其更强的鲁棒性，能够在各种尺寸和形状的肺栓塞分割中取得更为精确的结果，超越其他方法的表现。




图 2-4 中心 1 上不同方法的分割结果的视觉比较结果。红色表示标签，黄色表示分割结果。

Fig.2-4 Visual comparison of segmentation results of different methods on center 1.

Red represents the label and yellow represents the segmentation result.

表 2-3 在中心 2 上与其他分割模型的比较结果（%）。

Table 2-3 Comparison results with other segmentation models on center 2 (%).

方法	DSC	Jaccard	Sensitivity	BloU
UNet	60.15	44.03	47.01	42.52
UNet++	67.68	51.83	55.03	50.30
ResUNet++	64.25	48.58	50.61	47.09
AttU-Net	63.33	47.29	49.68	45.76
CPFNet	62.44	46.82	48.96	45.23
Swin-UNet	58.71	42.04	46.57	40.59
TransUNet	64.61	48.49	50.36	46.95
SCUNet++	68.98	53.31	56.02	51.80
nnUNet	<u>68.97</u>	<u>53.20</u>	<u>63.96</u>	<u>51.90</u>
Ours	76.90	62.65	73.05	61.07




图 2-5 中心 2 上不同方法的分割结果的视觉比较结果。红色表示标签，黄色表示分割结果。

Fig.2-5 Visual comparison of segmentation results of different methods on center 2.

Red represents the label and yellow represents the segmentation result.

2.5.3 不同分割方法在中心 2 数据上的性能比较

为了评估不同方法在跨中心测试中的稳健性，本章采用了在中心 1 上训练的模型在中心 2 上进行测试。比较结果如表 2-3 所示。可以观察到，DMCD-Net 在跨中心测试中的表现稳定，且在大多数评估指标中均取得了最好的性能，DSC 为 76.90%，Jaccard 为 62.65%，Sensitivity 为 73.05%，BIoU 为 61.07%。图 2-5 展示了在中心 2 上，不同 SOTA 方法的视觉分割结果。可以明显看到，当处理规则形状的大型肺栓塞时（如第 3 行所示），大部分方法均能够达到良好的分

割效果。然而，在处理小型肺栓塞（如第 1 行所示）或多样化大小和形状的肺栓塞（如第 2~3 行所示）时，这些方法的表现则明显下降。相比之下，DMCD-Net 在这些挑战性较大的场景中展现出了更强的分割能力，能够更有效地处理小型肺栓塞或位于较小动脉中的复杂形状，超越了其他方法。

2.5.4 不同分割方法在公开数据库 FUMPE 上的性能比较

使用 FUMPE 数据集进行了外部测试集的比较分析。由于外周肺动脉中肺栓塞的普遍性，这一数据集为肺栓塞分割任务带来了较大的挑战。表 2-4 中的实验结果显示，大多数方法在各项分割指标上均取得了中等水平的性能。然而，DMCD-Net 始终优于这些方法，能够更有效地应对 FUMPE 数据集中复杂且具有挑战性的情况。具体而言，与次优的 nnUNet 方法相比，DMCD-Net 在 DSC 上提高了 12.29%，在 Jaccard 上提高了 17.47%，在灵敏度上提高了 12.67%，而在 BIoU 上则提高了 20.26%。这些结果突显了 DMCD-Net 在处理肺栓塞分割任务时的优越性，尤其在面对复杂场景时的出色表现。

表 2-4 在 FUMPE 数据集上与其他分割模型的比较结果（%）。

Table 2-4 Comparison results with other segmentation models on the FUMPE dataset (%).

方法	DSC	Jaccard	Sensitivity	BIoU
UNet	35.46	23.92	26.48	23.49
UNet++	42.46	29.71	32.52	29.17
Resunet++	43.07	30.55	35.28	30.04
AttU-Net	41.85	29.71	32.37	29.22
CPFNet	46.35	33.02	36.96	32.41
Swin-UNet	44.10	30.06	34.42	29.40
TransUNet	43.59	30.54	33.78	30.04
SCUNet++	43.04	30.16	33.29	29.71
nnUNet	<u>49.48</u>	<u>34.91</u>	<u>49.08</u>	<u>34.16</u>
Ours	55.56	41.01	55.30	41.08




图 2-6 FUMPE 数据集上不同方法获得的分割结果的可靠性。

Fig.2-6 Reliability of segmentation results obtained by different methods on the FUMPE dataset.




图 2-7 在 FUMPE 数据集上不同方法的分割结果的视觉比较结果。

红色表示标签，黄色表示分割结果。

Fig.2-7 Visual comparison of segmentation results of different methods on the FUMPE dataset.Red indicates labels and yellow indicates segmentation results.

为了进一步说明不同方法之间分割结果的可靠性，在图 2-6 中展示了相应的结果。在图中，纵坐标表示 DSC 超过横坐标上相应阈值的比例。值得注意的是，DMCD-Net 在每个 Dice 阈值上超过的比例均高于其他方法，表明其分割结果的可靠性和一致性更强。

图 2-7 展示了 FUMPE 数据集上各种方法的视觉比较。可以明显看到，位于狭窄动脉中的小型肺栓塞（如第 1 行所示）对准确分割构成了较大挑战，尽管

这些栓塞的形状较为规则，但大多数方法在此类场景下的分割效果不理想。此外，复杂的边缘变化增加了主肺动脉内大型肺栓塞的分割难度（如第 3 行所示）。与其他方法相比，DMCD-Net 在处理这些不同情形时，始终能够保持较高的分割精度和稳健性，展现出更强的适应性和鲁棒性。

2.5.6 不同分割方法在公开数据库 CAD-PE 上的性能比较

在 CAD-PE 挑战数据集上对 DMCD-Net 的各种方法进行了全面评估。表 2-5 中的结果显示，DMCD-Net 在泛化性能方面优于现有方法。具体而言，与表现较差的 AttU-Net 方法相比，本章提出的 DMCD-Net 在 DSC 上提高了 58.63%，在 BIoU 上提高了 72.89%。此外，与次优的 nnUNet 方法相比，DMCD-Net 在 DSC 上提高了 9.09%，在 BIoU 上提高了 45.95%。这些结果表明，DMCD-Net 在处理肺栓塞分割任务时具有显著的泛化能力，尤其在复杂数据集集中的表现优越。

表 2-5 在 CAD-PE 挑战数据集上与其他分割模型的比较结果（%）。

Table 2-5 Comparison results with other segmentation models on the CAD-PE challenge dataset (%).

方法	DSC	Jaccard	Sensitivity	BIoU
UNet	32.92	21.42	22.71	21.04
UNet++	38.21	25.60	27.54	25.19
ResUNet++	35.61	23.34	25.07	22.93
AttU-Net	30.41	19.69	21.10	19.40
CPFNet	37.96	25.51	27.39	25.08
Swin-UNet	34.73	22.58	24.98	22.26
TransUNet	36.82	24.52	26.09	24.16
SCUNet++	38.30	25.65	28.43	25.25
nnUNet	<u>44.22</u>	<u>30.41</u>	<u>43.26</u>	<u>22.98</u>
Ours	48.24	34.07	43.80	33.54




图 2-8 在 CAD-PE 挑战数据集上不同方法的分割结果的视觉比较结果。

红色表示标签，黄色表示分割结果。

Fig.2-8 Visual comparison of segmentation results of different methods on the CAD-PE challenge dataset. Red indicates labels and yellow indicates segmentation results.

图 2-8 展示了使用 CAD-PE 挑战数据集进行的各种方法的视觉比较。与在 FUMPE 数据集中观察到的分割结果类似，主肺动脉内大型肺栓塞的分割性能受到复杂边缘变化的限制，从而影响了分割的准确性。DMCD-Net 在这些挑战性场景中展现了优秀的分割能力，并能够在各种具有复杂形状和结构的肺栓塞案例中保持更好的泛化性能，进一步验证了其在不同数据集中的稳健性和优越性。

2.6 本章讨论与结论

本章提出了一种名为 DMCD-Net 的深度学习模型，旨在提高肺栓塞分割的精度，以支持临床诊断。现有的肺栓塞分割方法受到多种挑战的限制，包括肺栓塞尺寸小、组织间相似性较高，以及肺栓塞形状不规则和位置变化等问题。为了解决这些问题，引入了 CT-DM 模块，以模拟 NCCT 和 CTPA 图像的协同诊断模式，并结合了 CDS 方案来引导网络关注难以分割的区域，从而提升肺栓塞分割的表现。随着 FUMPE 和 CAD-肺栓塞挑战数据集的发布，许多研究提出了基于计算机辅助诊断的方法来检测肺栓塞。然而，大多数现有的研究^[28, 87, 88]倾向于将像素级标签简化为切片级或区域级注释，以进行切片级诊断或区域级检测。因此，聚焦像素级的体素级分割问题的研究相对较少^[41, 82]。例如，Espinosa

等人^[36]在 CAD-PEChallenge 公共数据集上评估了基于 2D、2.5D 和 3DUNet 的网络的性能,获得了 0.485、0.367 和 0.296 的 DSC。这些基于像素或体素级分析的方法仍存在显著的性能差距。最近, Pu 等人^[40]引入了 R2-Unet, 在包含 91 名患者的私人数据集上实现了 0.676 的 DSC。尽管如此, 这些方法的稳健性依然无法得到充分保证。如表 2-3、2-3、2-4 和 2-5 所示, AttU-Net 和 CPFNet 在不同数据集上的分割性能存在差异, 这强调了它们对不同输入数据的敏感性。相比之下, DMCD-Net 表现出很强的泛化能力。为了进一步提升分割性能, 本章探索了 CTPA 和 NCCT 的协同诊断方法。与单独使用 CTPA 图像相比, 同时使用 CTPA 和 NCCT 图像的分割性能在 DSC 和 BIou 上分别提高了 0.62%和 0.76%。这表明, NCCT 图像为肺栓塞分割提供了额外的诊断信息。然而, 在实际应用中, 这种方法增加了 NCCT 扫描的成本, 并且 CTPA 和 NCCT 图像之间不可避免的空间配准误差可能会影响分割精度。为了解决配准误差带来的影响, 本章将合成的 NCCT 图像与真实的 CTPA 图像一起纳入分割模型中。与单独使用 CTPA 图像相比, 这种联合学习方法在 DSC 和 BIou 上的性能分别提高了 1.28%和 1.76%。尽管如此, 当合成和分割被视为两个独立任务时, 分割模型只能依赖 CTPA 和 NCCT 图像之间的强度差异。因此, 本章通过联合学习方式, 增强了对肺栓塞与周围组织之间多模态 CT 强度差异的理解, 从而提升了分割精度。与现有方法相比, DMCD-Net 在 DSC 和 BIou 上分别实现了 8.72%和 12.39%的改进, 取得了更为优异的性能。

尽管 DMCD-Net 表现出色, 但仍存在一些局限性。首先, 由于肺栓塞在 CTPA 图像中通常为小目标且属于少数类别, 这限制了本章方法的性能。未来的研究将侧重于小目标检测的方法, 并探索结合临床症状的数据进行综合分析。其次, 实验使用的数据集相对较小, 获取高质量的标注数据仍然是一项耗时且费力的工作。因此, 未来本章将进一步研究半监督学习方法, 以进一步提升肺栓塞分割的性能。

总的来说，本章提出的 DMCD-Net 能够有效提高肺栓塞分割的精度。结合了 CT-DM 模块和 CDS 方案，在不同医院和公共数据集上的实验结果表明，DMCD-Net 不仅优于现有的分割方法，而且在不同数据集上展现出了优秀的泛化能力。这些结果显示了 DMCD-Net 在推动肺栓塞诊断领域发展中的潜力。

第三章 基于 NCCT 图像的肺栓塞自动分割方法研究

3.1 本章引言

肺栓塞作为心血管疾病的主要致死因素之一，其早期准确诊断和及时干预对于改善患者的预后至关重要。CTPA 图像作为诊断肺栓塞的金标准，凭借其高分辨率和三维成像的影像优势，能够清晰显示肺动脉各亚段的充盈缺损情况，从而为临床提供准确的病变定位信息。通过静脉注射碘对比剂，CTPA 不仅能提供肺栓塞的空间分布信息，还可以用于评估血管病变程度，因此在急诊分诊、血管疾病的诊断和监测中得到了广泛应用^[89, 90]。尽管 CTPA 在肺栓塞中具有较高的诊断价值，CTPA 检查中对比剂的使用可能诱发过敏反应、肾功能障碍等不良反应，限制了其在特定患者群体中的应用^[91, 92]。相比之下，NCCT 图像作为一种高效、便捷的影像学检查手段，无需使用对比剂即可提供丰富的解剖结构信息，在肺栓塞诊断中展现出重要潜力。因此，如何在降低对比剂相关风险的同时维持诊断效能，已成为当前医学影像研究的重要课题之一^[93]。




图 3-1 肺栓塞在 CTPA 和 NCCT 图像上的影像学表现。

Fig.3-1 Imaging manifestations of pulmonary embolism on CTPA and NCCT images.

近年来，基于非增强图像的深度学习方法逐渐受到关注。现有研究主要通过迁移学习策略，将增强图像的特征表示迁移至非增强图像^[67, 94-96]，以减少对对比剂的依赖。然而，这些方法往往需要大量标注数据，且缺乏足够的视觉可解释性，限制了其临床应用。随着自监督学习在医学图像领域的快速发展，特别

是 MIM 的提出,为这一问题的解决提供了新的思路^[68, 69, 97]。自监督学习通过设计辅助任务,能够从大规模未标注数据集中提取有意义的视觉特征。其中, MIM 作为一种先进的自监督学习方法,在医学图像处理领域中取得了显著的进展。与传统依赖强度分类的自监督方法不同, MIM 是通过预测图像中被掩码区域的缺失像素来学习图像的潜在结构。在重建被掩码区域信号的过程中, MIM 能够有效促进图像中不同区域之间的上下文交互。在肺栓塞的识别过程中,准确处理对比剂相关信息至关重要。为此,本章创新性地将对对比剂视为 MIM 任务中的缺失信号,通过重建 CTPA 图像中的增强区域,模拟 NCCT 到 CTPA 的强度变化过程,从而提升模型对肺栓塞特征的识别能力。

同时, GAN 在医学图像合成领域中也取得了重要突破,特别是在从非增强图像到增强图像的转换过程中,能够提供更为直观的视觉解释^[48, 94, 98, 99]。尽管 GAN 生成的图像在视觉外观上具有较高可信度,但在应对复杂病变的诊断任务时,特别是对于肺栓塞这类需要精确区分病变特征的情况,其生成的图像往往难以包含足够的关键信息。为此,研究者们提出一系列基于深度学习的多任务联合合成与分割方法。这些方法通常包括两种主流框架: Y 型框架^[62, 63]和级联框架^[64, 65]。Y 型框架采用并行结构,在同一模型中同时进行合成和分割任务,通过共享潜在表示空间,实现两个任务之间的协同优化。而级联框架则更强调图像合成的质量,通过端到端的策略,或先合成高质量图像再进行分割的分步方式。

从 NCCT 图像中检测肺栓塞病变可以避免对比剂带来的潜在风险,但仍面临以下挑战: 1) 肺栓塞在 NCCT 图像中的可见性差(如图 3-1 所示): 肺栓塞在 NCCT 图像中表现为低对比度或模糊不清,导致病变特征难以提取; 2) 肺栓塞形态的复杂性与多样性: 在不同患者的 CT 图像中也可能展现出不同类型和形态的病变。

针对上述问题,本章提出了一种多任务对比剂掩码图像建模框架(Multi-task Contrast Agent Masked Image Modeling, MCAMIM),旨在通过自监督学习

的强大能力，提升基于 NCCT 图像的肺栓塞分割精度。该框架的核心在于充分利用对比剂引入后的强度差异，以增强对 NCCT 图像中肺栓塞的识别能力。通过自监督学习的对比剂对比掩码图像（Contrast Agent Masked Image Modeling, CAMIM），本方法能有效学习图像中的强度变化 and 对比剂的空间分布，为肺栓塞的分割任务提供丰富的先验知识。同时，引入联合合成-分割框架，通过共享视觉特征提升模型对关键信息的捕捉能力。该框架通过在合成和分割过程中共享关键视觉信息，促进模型对肺栓塞相关关键信息的捕捉与利用。本章方法为基于 NCCT 图像的肺栓塞检测提供了新的解决方案，在避免对比剂相关风险的同时，保持了良好的诊断性能。




图 3-2 本章方法的思路。

Fig.3-2 The idea behind the method in this chapter.

3.2 数据

3.2.1 数据集描述

本章采用北美放射学会公开的 CTPA 数据集^[100]进行预训练。并从珠江医院收集了 220 个病例数据，其中包括配对的 NCCT 和 CTPA 扫描图像，以及相应

的肺栓塞标签。在这些病例中，198 个病例被用于训练与验证模型，剩余的 22 个病例用于测试和评估模型的表现。出于对患者隐私的保护，从珠江医院收集的所有医学图像在使用前均已按照伦理与信息安全要求进行规范化脱敏处理，去除了患者姓名、身份证号、检查时间、机构编号等所有可能识别个体身份的信息。数据的获取与使用严格依据研究单位的内部数据安全协议，并在权限受控、物理隔离的环境下完成，确保研究过程中的数据隐私与合规性。

3.2.2 数据预处理

为确保 NCCT 和 CECT 的空间一致性，采用 FSL 进行仿射配准，并结合 ANTs 的对称归一化算法优化配准精度。考虑到 CT 图像中亨斯菲尔德单位范围较宽，且肺栓塞等目标区域在 CT 图像中的边界较为模糊，选用了分段最小最大归一化方法，通过设定不同的阈值来有效突出增强组织的特征，从而提高目标区域的辨识度。此外，为了确保统一的数据输入格式，所有 CT 图像均被线性归一化至 $[-1, 1]$ 的标准范围，确保其适应于后续的深度学习模型训练。在图像预处理过程中，通过阈值化和孔填充技术生成了 CT 图像的掩模进行去床操作。通过阈值化方法，图像中的非目标区域被有效过滤，保留了关键的结构信息，从而减少了背景噪声的干扰。孔填充技术则用于填补图像中的空洞，确保了生成的掩模连通性和完整性，后续分割任务提供了更精确的图像掩模。

3.3 基于多任务对比剂掩码图像建模的肺栓塞自动分割方法

3.3.1 问题表述

本章的研究目标是构建一个基于 NCCT 图像的肺栓塞自动分割模型。给定数据集 $\mathcal{D} = (X_i^{NCCT}, Y_i)_{i=1}^n$ ，其中 $X_i^{NCCT} \in \mathbb{R}^{D \cdot H \cdot W \cdot 1}$ 表示 NCCT 图像， Y_i 表示肺栓塞

对应的真实值标签。目标是训练一个分割模型 $\hat{Y} = \mathbb{P}(X^{NCCT})$ 。现有的基于非增强图像的分割方法通常依赖于标记数据，且缺乏直观的视觉可解释性。为了解决这些问题，本章提出了 MCAMIM 来捕捉对比剂引入的强度变化和视觉差异。MCAMIM 采用了合成-分割联合学习策略，用于 NCCT 图像中的肺栓塞分割。




图 3-3 MCAMIM 框架图。

Fig.3-3 MCAMIM framework diagram.

3.3.2 整体框架 MCAMIM

肺栓塞在 CTPA 图像中通常表现为典型的填充缺损,但由于缺乏对比剂可视化,其在 NCCT 图像中的识别难度显著增加。为了解决这一挑战,本章提出了 MCAMIM,将对比剂视为 MIM 中的恢复信号。具体而言,CAMIM 通过引入额

外的图像对比度恢复任务，扩展了传统 MIM 框架中的代理任务。该方法旨在重建 CTPA 图像中的增强区域，并模拟 NCCT 图像中从对比剂缺失到对比剂存在的过程（如图 3-2 所示）。这种设计能够有效捕捉强度变化与对比剂分布模式，弥合 CTPA 和 NCCT 图像之间的特征差距，从而准确识别 NCCT 图像中的肺栓塞。

考虑到目前公开的 CTPA 数据集通常缺乏配对的 NCCT 数据，引入了一个去增强模型以得到相应的 NCCT 图像。如图 3-3 所示，去增强模型利用了两个公开可用的分割模型：Lung segmentation model 用于肺野分割和 Vessel segmentation model 用于肺动脉分割。通过这些分割模型生成的分割掩膜，可以有效识别 CTPA 图像中的增强区域。随后，通过应用强度映射和直方图平滑技术，将增强区域的强度调整至与 NCCT 图像经验强度范围相匹配，从而得到 NCCT 图像。在该框架中，CTPA 和 NCCT 图像被联合用于模型训练。其中，CTPA 图像为模型提供了准确的对比度分布，帮助其有效学习 NCCT 图像中与肺栓塞相关的对比度特征与强度变化模式。训练 CAMIM 的损失函数可以表示为：

$$\mathcal{L}_{CAMIM} = \|X^{CTPA \rightarrow CTPA} - X^{CTPA}\|_1 + \|X^{NCCT \rightarrow CTPA} - X^{CTPA}\|. \quad (3.1)$$

在训练 MCAMIM 的过程中，采用了合成与分割的联合多任务学习策略。

损失函数由合成和分割两部分组成，可以表示为：

$$\mathcal{L} = \mathcal{L}_{Sys} + \mathcal{L}_{Seg}, \quad (3.2)$$

合成损失函数可以表示为，其中 X^{CTPA} 表示为真实的 CTPA 图像， $X^{NCCT \rightarrow CTPA}$ 表示为由 NCCT 得到的合成 CTPA 图像：

$$\mathcal{L}_{Sys} = \|X^{NCCT \rightarrow CTPA} - X^{CTPA}\|, \quad (3.3)$$

分割损失函数可以表示为：

$$\mathcal{L}_{Seg} = \mathcal{L}_{CE}(\hat{Y}, Y) + \mathcal{L}_{Dice}(\hat{Y}, Y), \quad (3.4)$$

通过联合损失函数，MCAMIM 能够在训练过程中同时优化图像合成和分割任务，

从而提升模型在 NCCT 图像中分割肺栓塞的准确性。

3.3.3 模型结构

CAMIM 的编码器由十二个 Transformer 层组成，并在解码器部分引入了八个 Transformer 层。Transformer 编码器用于建模掩码区域的潜在特征表示，并利用这些特征预测掩码区域中的原始信号。在此过程中，掩码区域对于 Transformer 编码器不可见，而完整的图像特征则被输入 Transformer 解码器进行重建。这一设计有效降低了计算和内存开销，同时保持了高效的训练效率。在合成和分割解码器的设计中，使用了 UNETR^[101] 的解码器。UNETR 是一种专门针对医学图像分割设计的 U 型编码解码架构，结合了 Transformer 主干编码器的与基于 U-Net 设计的卷积上采样解码器。首先将输入尺寸为 $256 \times 256 \times 16$ 的三维图像转化为序列嵌入，并划分得到 $16 \times 16 \times 8$ 的不重叠图像块，每个图像块的特征维度为 $16 \times 16 \times 2 = 512$ 。随后，通过线性层将特征维度投影为 C 维，作为 Transformer 编码器的输入。在 Transformer 编码器中提取多层的编码特征表示通过跳过连接与解码器融合，最终生成输出结果。

3.4 实验细节

3.4.1 实验设置

在本研究中，模型输入大小设置为 $256 \times 256 \times 16$ ，并且批次大小设置为 2，以适应自监督学习的训练过程。采用了数据增强方法，包括随机平移和翻转，以增加训练数据的多样性，进而提高模型的泛化能力。优化器选用了 Adam，并结合 poly decay 策略动态调整学习率，初始学习率设置为 2×10^{-4} ，旨在优化训练过程中的模型性能和收敛速度。所有实验均在 Pytorch 上实现，并使用配备 11GB

显存的 NVIDIA RTX 2080Ti GPU 进行训练。这一配置为模型提供了足够的计算资源，确保了大规模数据集的高效处理和复杂模型的训练过程。

3.4.2 评价指标

为了定量评估不同方法在肺栓塞分割任务中的性能，实验使用了五个常用的评价指标：DSC、Jaccard、Sensitivity 以及 BIoU。这些指标能够从多个角度全面反映分割结果的质量，具体描述如下：DSC 定义为预测结果与真实标签交集的两倍除以其面积之和。用于评估预测结果与真实标签之间的相似性，DSC 可以反映分割结果的整体一致性。Jaccard 定义为预测结果与真实标签交集在两者并集中的比例。用于评估预测结果与真实标签之间的相似程度，强调对误差的敏感性。Sensitivity 衡量了分割模型对肺栓塞区域（真实阳性样本）的识别能力。BIoU 评估了分割边界的精确度，尤其适用于肺栓塞这种形状复杂、不规则的病变区域的分割任务。

3.5 实验结果与分析

3.5.1 消融实验

为了进一步验证 MCAMIM 中关键模块的有效性，设计并进行了系统的消融实验。实验结果如表 3-1 所示，UNETR 作为基线模型 Baseline，未应用任何自监督策略，其 DSC 仅为 1.52%，Jaccard 为 0.79%，Sensitivity 为 0.79%，BIoU 为 0.67%。这一结果表明，基线模型性能表现较为有限，难以有效捕捉医学图像中的复杂特征。

在基线模型的基础上，引入了分割与 CT-CTPA 合成联合任务（Segmentation-Synthetic, SS），即通过同时优化分割和图像合成任务。实验结果显示，加入 SS 后，模型的性能由 DSC 从 1.52%提升至 9.14%，Jaccard 提升至

表 3-1 不同模块上的消融实验结果(%)。

Table 3-1 Ablation experiment results on different modules (%)

模型	MIM-based Pre-Training Method	DSC	Jaccard	Sensitivity	BloU
Baseline	-	1.52	0.79	0.79	0.67
Baseline w SS	-	<u>9.14</u>	<u>5.14</u>	<u>5.39</u>	<u>4.97</u>
Baseline w SS	CAMIM	50.63	34.54	58.40	33.52




图 3-4 CAMIM 的训练效果。

Fig.3-4 Training effect of CAMIM.

5.14%，Sensitivity 提升至 5.39%，BIoU 提升至 4.97%。进一步引入了 CAMIM 模块，DSC 从 9.14%大幅提升至 50.63%，Jaccard 提升至 34.54%，Sensitivity 提升至 58.40%，BIoU 提升至 33.52%。CAMIM 模块能够有效捕捉医学图像中的上下文信息，并通过注意力机制优化特征表示，从而提高分割精度。

在图 3-4 中展示了 CAMIM 训练过程中重建图像的效果演变。训练初期，重建图像表现为随机噪声，未能捕捉到任何有意义的解剖结构信息。表明模型在初始阶段尚未学习到有效的特征表示，重建结果与真实图像之间存在显著差异。随着训练的进行，模型开始学习到整体解剖结构的位置关系，重建图像的质量提升。特别是在肺动脉区域，恢复的图像强度与真实图像之间的差距逐渐缩小。训练后期，重建图像在肺动脉区域的细节还原度显著提高，与真实图像的强度分布趋于一致，进一步验证了 CAMIM 在医学图像重建任务中的有效性。

3.5.2 不同方法的性能比较

为了全面评估自监督方法在医学图像分割任务中的效果，本研究将提出的 MCAMIM 方法与当前最先进的自监督预训练方法（如 MAE 和 SimMIM）进行了对比实验。实验结果如表 3-2 所示，MCAMIM 在多个关键性能指标上均展现出优势，进一步验证了其在医学图像分割任务中的有效性。从定量结果来看，MAE 方法在 DSC、Jaccard、Sensitivity 和 BIoU 等指标上的表现分别为 37.39%、23.58%、32.35%和 22.96%。SimMIM 方法在这些指标上有所提升，分别达到 45.19%、30.06%、50.44%、99.95%和 28.80%。与这两种方法相比，MCAMIM 在各项指标上均取得了更优的表现：DSC 达到 50.63%，Jaccard 为 34.54%，Sensitivity 为 58.40%，BIoU 为 33.52%。从定性结果来看（如图 3-5 所示）MAE 和 SimMIM 在某些复杂场景下容易出现分割错误的问题，MCAMIM 生成的分割结果与标签更加接近。

表 3-2 不同自监督方法的实验结果（%）。

Table 3-2 Experimental results of different self-supervision methods (%).

MIM-based Pre-Training Method	DSC	Jaccard	Sensitivity	BloU
MAE	37.39	23.58	32.35	22.96
SimMIM	<u>45.19</u>	<u>30.06</u>	<u>50.44</u>	<u>28.80</u>
Ours	50.63	34.54	58.40	33.52




图 3-5 不同方法结果的可视化。

Fig. 3-5 Visualization of the results of different methods.

3.6 本章讨论与结论

本章提出了 MCAMIM，结合对比掩码图像建模和联合合成-分割策略，以提高基于 NCCT 图像的肺栓塞分割性能。当前，肺栓塞的自动识别主要依赖 CTPA 图像，但由于对比剂使用带来的副作用，探索基于 NCCT 图像的分割方法具有重要的临床价值。然而，肺栓塞在 NCCT 图像中的对比度较低，且形态复杂，给自动分割带来了较大挑战。现有方法多采用图像增强策略或迁移学习来提升

非增强 CT 图像的肺栓塞检测性能。然而，这些方法在数据稀缺和配准误差的情况下仍面临着挑战。尽管 MCAMIM 取得了良好的实验结果，但仍然存在一定的局限性。首先，由于肺栓塞在 NCCT 图像中的视觉特征较为模糊，导致模型在小体积病变的分割上仍存在误差。未来研究可以结合基于注意力机制的方法，以进一步增强模型对小病灶的识别能力。其次，MCAMIM 框架目前依赖于合成图像，未来可以结合自监督学习和迁移学习策略，减少对合成数据的依赖，提高模型的自主学习能力。

第四章 胸部结构自动分割系统

4.1 本章引言

胸部结构分割在胸部疾病诊断、治疗规划和预后评估中具有重要的临床价值。通过对肺动脉、肺野、心脏、气道及骨头等关键解剖结构的精确分割,医生可以更全面地评估患者的肺栓塞严重程度、心肺功能状态及相关并发症,从而制定个性化的治疗策略。准确的分割结果可为临床诊断提供有价值的信息,如器官大小、位置、边界状态、多器官空间关系等^[61]。对于急性肺栓塞患者,肺栓塞分割结果能够有效量化血栓负荷,为溶栓或机械取栓等介入治疗提供重要依据^[102]。此外,心脏分割有助于评估心室负荷,而气道及骨头的分割则能够降低伪影对肺栓塞诊断的干扰。肺动脉和肺野的精确分割能够帮助定位肺栓塞的位置,提高诊疗的准确性和可靠性。

然而,胸部结构分割任务面临解剖结构差异大、软组织对比度低以及观察者间一致性不足等诸多挑战。传统基于规则的方法(如阈值分割、霍夫变换和水平集方法)难以处理复杂的解剖结构和CT图像的多样性。近年来,CNN在医学图像分割取得优异的性能,基于深度学习的分割技术在临床实践中具有重要的潜力,能够加快勾画过程,并提高分割准确性和一致性^[103]。

本章旨在开发一套基于深度学习的胸部结构自动分割系统,能够对CT图像中的骨头、肺野、心脏、肺动脉和气道五大解剖结构以及肺栓塞病变进行像素级分割。胸部多器官使用的深度学习模型为CNN,其网络结构采用编码器和解码器对称的结构设计,充分利用空间结构进行端到端训练,实现了高效的分割。肺栓塞分割模型为第二章提出的基于CTPA图像的肺栓塞分割方法和第三章提出的基于NCCT图像的肺栓塞分割方法。为进一步提升系统的可用性并方便医生使用,本章开发了一个用户友好的图形用户界面(Graphical User Interface, GUI)。该系统基于Python编程语言开发,使用了PyCharm、Qt Designer和pyui5

工具进行图形界面编程。所有实验均在 Linux 和 Window 操作系统上完成,使用 Pytorch 1.7.1、Python 3.8.5 和 PyQt5 5.15.6,并在 NVIDIA GeForce RTX 2080 显卡上运行。该系统提供了高效便捷的交互界面,用户在加载 CT 图像后,可以调用 AI 模型接口 1 进行胸部多器官分割, AI 模型接口 2 或 AI 模型接口 3 进行肺栓塞分割,以及调用接口 4 对器官的边缘进行检测。当用户想对某一感兴趣器官或病变进行仔细观察时,系统提供了器官/病变选择的功能,可以单独展示骨头、肺野、心脏、肺动脉、气道和肺栓塞的分割结果。支持通过切片控制功能以实现连续阅片,同时配备三维示意图直观显示胸部多器官的三维立体结构。本系统能够自动加载 CT 图像并执行器官分割与边缘检测,辅助医生准确快速地识别胸部结构,提高诊疗效率和准确度,并丰富临床医生的诊疗手段。

4.2 目标与需求分析

4.2.1 目标

本章的主要目标是构建一套胸部多器官结构自动分割识别系统。如图 4-1 所示,该系统的核心功能包括数据输入、器官分割、器官边缘检测及肺栓塞分割,同时实现图像展示、切片控制、功能切换和器官选择等基本操作。具体而言,用户可以通过 GUI 加载胸部 CT 图像序列,并通过 AI 模型接口 1、接口 2 和接口 3 实现自动分割。系统还支持通过功能切换调用 AI 模型接口 4 进行器官边缘检测。此外,用户可以通过器官/病变选择功能,单独展示骨头、肺野、心脏、肺动脉、气道和肺栓塞的分割结果。用户可通过切片控制功能实现连续阅片。同时,系统提供了三维示意图,直观展示胸部多器官的立体结构。

该系统的设计目标旨在提升胸部 CT 图像的自动化分析效率和准确性。通过集成深度学习模型与用户友好的交互界面,本系统能够提高医生的工作效率,并为肺栓塞及其他胸部疾病的诊断提供辅助工具。




图 4-1 胸部结构自动分割系统实现的功能。

Fig.4-1 Functions realized by the automatic segmentation system for chest structures.

4.2.2 需求分析

在现有的临床实践中，医生通常需要在 CT 图像上手动勾画感兴趣的器官，尤其是在疾病的早期诊断和精准治疗过程中。经验丰富的医生通常会基于器官的解剖位置关系进行标注，例如，食管位于心脏后方，气管位于脊髓上方等。尽管 CT 图像提供了较为准确的几何信息，但需要标注的器官种类繁多，且其形状和大小差异显著。此外，由于不同患者之间的解剖结构差异、软组织对比度不足及器官形态的相似性等因素，人工标注往往要求医生具备高度的专业技能和丰富的经验。因此，人工勾画不仅增加了医生的工作强度，还可能影响分割的一致性和准确性。

基于上述挑战，本章提出了一种基于深度学习技术的胸部多器官结构自动分割识别系统。该系统能够对 CT 图像中的五大类解剖结构（骨头、肺野、心脏、肺动脉、气道）以及肺栓塞病变进行像素级别的分割。这一自动化分割过程有效减轻了医生的工作负担，并提高了分割效率与准确度。通过该系统，临床医生能够更加迅速、准确地识别胸部结构，进而优化诊疗决策，在疾病的早期诊断与个性化治疗方面提供支持。




图 4-2 系统分割与边缘检测算法两个核心功能实现的示意图。

Fig.4-2 Schematic diagram of the implementation of the two core functions of the system segmentation and edge detection algorithm.

4.3 系统总体设计

根据前述目标，本章首先基于深度学习技术构建了自动分割模型，以实现
对胸部多器官结构的精准分割。随后，系统利用 SciPy 库中的 distance transform
edt 函数计算器官分割结果的欧几里得距离变换，从而提取器官的边缘信息。在
完成分割与边缘检测这两个核心功能后，系统借助 Python 图形界面编程技术开
发了一个便于操作的 GUI。最终，系统实现了胸部多器官结构自动分割识别系
统的所有功能，并提供了便捷的交互界面。

4.4 系统实现

4.4.1 系统开发环境

本系统是用 Python 编程语言开发的，使用了 PyCharm、Qt Designer 和 pyuic5
进行 Python 图形界面编程。所有的实验都是在 Linux 和 Window 操作系统上，
使用 Pytorch 1.7.1、Python 3.8.5 和 PyQt5 5.15.6 在 NVIDIA GeForce RTX 2080

上完成的。

4.4.2 数据集

在医学领域，胸部多器官数据集的构建对于疾病诊断和治疗方案的制定具有重要意义。然而，由于涉及到患者隐私保护、需要具备相关专业医学知识的医师勾画对目标器官进行勾画以及多器官解剖结构的复杂性，现有研究普遍面临数据集规模小、器官覆盖不全的局限性。由表 4-1 所示，现有研究^[103-109]结合实际需求对胸部各类器官成像数据进行收集勾画，但由于研究目标不同，以及多器官解剖结构的复杂性使得人工标注需要耗费大量的精力和时间，因此在相关的研究中所使用的样本数量有限，包含的器官种类并不相同也不全面。因此，构建一个包含全面的胸部多器官数据是必要且具有研究意义的。

本章采用的胸部多器官数据来源于珠江医院，共收集了 50 例 CTPA 扫描数据。原始数据从标准 DICOM 格式转换为 NIfTI 格式，以便于后续处理。每例数据的层间距为 5mm，图像的轴向宽度和长度均为 512，图像分辨率范围为 0.6523 到 0.7011 之间。所有胸部多器官标注均由经验丰富的临床医生完成，如图 4-3 所示。

表 4-1 胸部多器官公开数据库统计。

Table 4-1 Statistics of chest multi-organ public database.

年份	网络架构	类型	器官	数据大小
2019	2D and 3D CNN ^[104]	2D 、 3D	心脏、主动脉、食管、气管	40 例
2018	Dilated U-Net ^[105]	2D	左右肺、食管、脊椎	900 张切片
2020	3D Dense V-Net ^[106]	3D	心脏、主动脉、食管、气管	40 例
2019	U-Net-GAN ^[103]	3D	左右肺、心脏、食管、脊椎	35 例
2019	Distance-aware GAN ^[107]	2D	左右肺、心脏、食管、椎骨	11084 张切片
2019	VB-Nets ^[108]	3D	心脏、主动脉、食管、气管	40 例
2022	3D U-Net ^[109]	3D	左右肺、心脏、食管、脊椎	260 例




图 4-3 使用的胸部多器官数据标注示意图。

Fig.4-3 Schematic diagram of chest multi-organ data annotation used.

为充分评估模型性能，实验采用五折交叉验证策略，确保每折训练集与测试集间无数据分布重叠。出于对患者隐私的保护，所有医学图像在使用前均已按照伦理与信息安全要求进行规范化脱敏处理，去除了患者姓名、身份证号、检查时间、机构编号等所有可能识别个体身份的信息。数据的获取与使用严格依据研究单位的内部数据安全协议，并在权限受控、物理隔离的环境下完成，确保研究过程中的数据隐私与合规性。

4.4.3 基于深度学习的胸部多器官自动分割模型构建

4.4.3.1 模型架构与训练策略

准确地多器官分割是一项具有挑战性的任务。不同器官的形状和位置差异很大，需要通过实验设计合适的深度学习网络，能够兼容强语义信息和精细空间细节信息进行复杂特征的提取，实现对各类器官的准确分割。UNet^[110]是目前最常用的医学图像分割模型，由用于捕获上下文的收缩路径和用于实现图像中目标区域精确定位的对称扩展路径组成。UNet 是一种典型的编码器-解码器结构，编码器逐渐降低池化层的空间维数，解码器逐渐修复对象的细节和空间维数。编码器和解码器之间通常有一个跳跃连接，这有助于解码器准确地重建目标。

实验模型采用 nnUNet^[111]，nnUNet 提供了一个通用的对医学图像分割自动



图 4-4 构建基于深度学习的多器官自动分割模型示意图。

Fig.4-4 Schematic diagram of building a multi-organ automatic segmentation model based on deep learning.

进行配置的框架，可以自动的根据不同的数据集的进行自适应预处理，神经网络设计，训练以及后处理。如图 4-4 所示，首先对训练数据进行去床和 Z-score 标准化，包括随机旋转、随机缩放、随机弹性形变、Gamma 矫正增强及镜像的数据扩增。此外为了兼顾 3D 结构信息的保留与节省内存开销，本章将 CT 图像划分为图像块，再送入 3D U-Net 进行多器官分割训练。

在医学影像数据集中，图像大小往往由于需要诊断的组织类型位置不同而存在差异。需要综合考虑空间上下文聚合和实际显存大小来决定输入的图像大小以保证模型性能。实验使用的数据是 3D 医学图像，对应采用 3D U-Net，网络结构如图 4-5 所示。根据显存大小，3D U-Net 的输入图像大小设置为 $24 \times 256 \times 256$ ，批次大小设置为 2，分辨率最高的特征图通道数大小设置为 20，沿每个轴最多池化 5 次直到特征图的分辨率设置为 $6 \times 8 \times 8$ 。损失函数采用 Dice 损失和交叉熵损失之和，以平衡类别不均衡问题并提高分割精度。优化器选择 Adam，相较于固定学习率的随机梯度下降，Adam 通过梯度的一阶矩估计和二阶矩估计动态调整学习率，从而加快收敛速度并提高稳定性。迭代次数最终选择 500，并采用动态学习率调整策略，初始学习率设为 3×10^{-4} ，基于训练集和验证集的指




图 4-5 3D U-Net 网络结构示意图。

Fig.4-5 Schematic diagram of 3D U-Net network structure.

数滑动平均损失进行调整，如果训练集的指数滑动平均损失在最近 30 次迭代中减少不足 5×10^{-3} ，则学习率衰减 5 倍。为增强网络训练的稳定性，每个批次中超过 1/3 的样本包含至少一个随机选择的前景区域。由于训练和测试均采用图像块形式的输入方式，而模型的预测精度在图像块边缘区域可能会有所下降，因此在沿各镜像轴进行图像块集成时，采用滑窗重叠方式进行拼接，以确保整张图像的预测精度。

4.4.3.2 评价指标

为了定量评估分割任务的性能，实验使用了四个常用的评价指标：DSC、精确度（Accuracy）和敏感性（Sensitivity）。这些指标能够从多个角度全面反映分割结果的质量，具体描述如下：DSC 定义为预测结果与真实标签交集的两倍除以其面积之和。用于评估预测结果与真实标签之间的相似性，DSC 可以反映分割结果的整体一致性。Accuracy 反映了分割模型在所有样本中的正确分类比例。Sensitivity 衡量了分割模型对真实阳性样本的识别能力。

表 4-2 五折交叉验证分割结果的性能评估。

Table 4-2 Performance evaluation of segmentation results in five-fold cross validation.

区域	指标	Fold-1	Fold-2	Fold-3	Fold-4	Fold-5	平均
肺动脉	DSC	0.894	0.886	0.898	0.877	0.867	0.884
	Accuracy	0.911	0.910	0.910	0.892	0.871	0.899
	Sensitivity	0.884	0.866	0.888	0.865	0.868	0.874
心脏	DSC	0.936	0.956	0.946	0.960	0.923	0.944
	Accuracy	0.939	0.951	0.946	0.960	0.923	0.944
	Sensitivity	0.936	0.963	0.947	0.960	0.925	0.946
骨头	DSC	0.950	0.958	0.956	0.955	0.951	0.954
	Accuracy	0.960	0.960	0.959	0.962	0.948	0.958
	Sensitivity	0.941	0.956	0.953	0.949	0.953	0.950
肺野	DSC	0.974	0.969	0.973	0.984	0.952	0.970
	Accuracy	0.979	0.959	0.976	0.984	0.948	0.969
	Sensitivity	0.970	0.982	0.971	0.985	0.959	0.973
气道	DSC	0.949	0.949	0.941	0.944	0.942	0.945
	Accuracy	0.938	0.968	0.948	0.941	0.936	0.946
	Sensitivity	0.961	0.933	0.935	0.949	0.950	0.946

4.4.3.3 实验结果与分析

通过五折交叉验证评估了五类胸部器官的分割性能，分别为肺动脉、心脏、骨头、肺野和气道。表 4-2 展示了每一折的分割结果以及五折的平均性能指标。肺动脉的分割结果整体表现良好，平均 DSC 达到 0.884，该区域的分割效果较为稳定。心脏的分割表现为各项指标中最优之一，平均 DSC 为 0.944，Accuracy 和 Sensitivity 分别为 0.944 和 0.946，表明该区域的分割非常精准且完整。骨头分割的性能也表现较好，平均 DSC 为 0.954。Accuracy 为 0.958 和 Sensitivity 为 0.950，表明模型能够准确地识别骨头区域，且漏检率较低。肺野的分割结果同样优异，平均 DSC 为 0.970。Accuracy 为 0.969，Sensitivity 为 0.973，表明该区域的分割效果稳定且准确。气道的分割在各项指标中表现稳健，平均 DSC 为

0.945, Accuracy 和 Sensitivity 分别为 0.946 和 0.946, 表明模型在气道分割中的表现均衡。从五类分割结果来看, 肺动脉、心脏、骨头、肺野和气道的分割效果均表现较为理想, 尤其是在 Accuracy 和 Sensitivity 方面, 显示出模型能够有效区分各类胸部器官。

4.4.4 胸部多器官边缘自动检测算法设计

在本章中, 多器官边缘检测的实现采用了基于最短路径算法的方法, 结合欧几里得距离度量计算图像中各个像素点与零值像素之间的距离。该方法通过将图像中所有非零值的像素视为图中的节点, 进一步利用最短路径算法计算每个节点的最短路径, 最终获得各个像素点到最近零值像素的欧几里得距离。为实现该边缘检测功能, 本研究使用了 PyTorch 中的 `distance transform edt` 函数。该函数可用于计算二值图像中每个像素与最近零值像素的欧几里得距离, 返回的结果为一个距离图像。考虑到多器官分割模型的输出是五类标签图像, 本算法设计了如下的多器官边缘检测算法, 结合了最短路径算法的优势, 成功实现了对五种不同器官的边缘检测。

算法流程如下:

- (1) 输入数据: 从多器官分割模型获取分割结果, 记为 `output`。该输出是一个包含五类标签的图像, 表示不同器官的区域。
- (2) 标签定义: 定义一个标签变量 `label`, 用于表示每个器官的边缘。在标签图像中, 肺动脉的标签值设为 1, 心脏设为 2, 骨头设为 3, 肺野设为 4, 气道设为 5。
- (3) 边缘检测函数定义: 依据最短路径算法设计器官边缘检测函数。该函数的核心思想是根据每个器官区域与其他区域的最短距离来定义边缘。具体的函数如下所示:

def Organ margin detection(label, output):

```
label[output != label] = 0  
margin = distance transform edt(label)  
margin[margin == 1] = label  
return margin
```

(4) 标签赋值：根据器官的标签值（肺动脉=1，心脏=2，骨头=3，肺野=4，气道=5），依次为 label 分配相应的标签值，并将该标签与 output 一起送入边缘检测函数。根据每个器官的标签值，得到对应的器官边缘检测结果。

(5) 结果融合：最后，将五个器官的边缘检测结果进行叠加和组合，得到最终的多器官边缘检测结果。

通过上述步骤，本算法能够对不同器官的边缘进行有效提取。通过将每个图像像素与最近零值像素的距离作为依据，该算法能够有效避免传统方法中因边缘模糊或噪声干扰而导致的边缘检测不准确问题。此外，PyTorch 中的 distance transform edt 函数被高效地应用于二值图像处理，该函数优化了计算过程，显著提高了边缘检测的速度和精度，尤其适合大规模医学图像的处理。考虑到多器官分割模型通常输出多个器官的标签信息，本算法充分利用这些标签，通过独立提取各器官边缘并将结果合成，提供了高精度的多器官边缘检测结果。




图 4-6 胸部多器官边缘自动检测示意图。

Fig.4-6 Schematic diagram of automatic detection of edges of multiple organs in the chest.

通过上述方法,本研究成功实现了基于最短路径算法的多器官边缘检测,具备较高的精度和效率。

4.4.5 系统 GUI 设计与开发

为了让方便用户方便,本章设计开发了胸部多器官结构自动分割系统的交互界面。对于 GUI 的开发,选择采用结合了 python 图形化界面编程 PyCharm、Qt Designer 和 pyuic5 来实现。

4.4.5.1 GUI 简介

GUI 是通过图形化方式呈现计算机操作界面的技术,它允许用户通过鼠标等输入设备与计算机进行交互,控制图标、菜单选项等界面元素,从而选择命令、调用文件、启动程序或执行其他日常任务。GUI 的引入极大地简化了人与计算机之间的交互方式,使得计算机程序更加易于操作,尤其对于非专业用户而言,提供了直观且高效的操作体验。

Qt 库是由 Riverbank Computing 开发的一款功能强大的 GUI 开发框架,是目前应用广泛且备受推崇的 GUI 库之一。Qt 不仅提供了丰富的界面控件和功能,还附带了 Qt Designer 设计工具,能够通过图形化界面实现控件的拖拽式布局,极大地简化了界面设计和开发过程。Python 作为一门广泛应用的编程语言,支持多种图形界面库,如 Tkinter、wxPython 和 PyQt 等。其中,PyQt5 是由 Digia 公司开发的 Qt5 应用框架与 Python 语言的结合,能够在 Unix、Windows 和 macOS 等主流操作系统上高效运行。在 PyQt5 中,用户既可以通过直接编写代码实现 UI 界面的构建,也可以通过 Qt Designer 进行图形化设计。Qt Designer 符合模型-视图-控制器架构设计思想,通过将视图和逻辑进行分离,优化了界面与程序逻辑的开发和维护。此外,Qt Designer 提供了灵活的控件布局方式,支持通过拖

拽操作实时预览控件效果，极大提升了开发效率和界面设计的便捷性。

4.4.5.2 使用 QT Desinger 设计程序主界面

在 Qt Designer 中，提供了八大类界面可视化组件（控件盒）在 Qt Designer 的应用界面设计时，可以将各种功能的组件拖拽到窗口上进行应用的可视化界面设计，而每种组件又可以指定不同的属性。




图 4-7 Qt Designer 界面。

Fig.4-7 Qt Designer interface.

以下是本章中使用的主要控件盒及其功能说明：

(1) Layouts—Vertical Layout

功能说明：该控件用于实现控件的垂直排列。首先拖动出该控件后，用户可以将需要对齐的其他控件放置于其中，从而实现控件的自动排列。

具体应用：在本章中，“骨头”“肺野”“心脏”“肺动脉”和“气道”按钮及其相应图标通过此控件在垂直方向上对齐，确保界面的整洁与一致性。

(2) Buttons—Push Button

功能说明：Push Button 控件可发射信号，并通过与槽函数的配合，实现与用户交互的功能。在本章中，按钮控件主要用于触发特定任务或操作。

具体应用：包括“加载”按钮（用于加载 CT 图像）、“多器官分割”按钮（触发多器官分割过程）、“基于 CTPA 的肺栓塞分割”、“基于 NCCT 的肺栓塞分割”按钮（触发肺栓塞分割过程）、“器官检测”按钮（用于进行多器官边缘检测）的设计。

（3） Display Widgets—Label

功能说明：Label 控件用于显示文本或图像内容，可以接收信号，并通过槽函数实现动态显示功能。该控件在界面设计中起到了信息展示的关键作用。

具体应用：在本章中，使用 Label 控件展示 CT 图像的不同切面（矢状面、冠状面及轴状面），以及胸部多器官的 3D 示意图、分割结果、边缘检测结果等内容，直观呈现图像处理的各个阶段。

（4） Input Widget—Text Edit

功能说明：Text Edit 控件用于显示多行文本，适用于需要展示大量信息或进行用户输入的场景。

具体应用：在本章中，Text Edit 控件用于显示图示说明和切片说明，提供详细的图像分析或操作步骤说明，方便用户理解。

（5） Input Widget—Horizontal Slicer

功能说明：Horizontal Slicer 控件允许用户在图像切片间进行滑动，从而查看不同切片的内容。

具体应用：该控件在本章中用于实现 CT 图像的切片浏览功能，使用户能够便捷地查看不同水平面的 CT 图像，增强图像分析的交互性。

通过合理的控件组合与属性配置，Qt Designer 为本章的 GUI 提供了极大的便利，使得用户可以在直观、简洁的界面中完成复杂的医学图像分析任务。这些界面组件不仅优化了用户体验，也提高了程序的操作性和功能性。

4.5 系统测试

4.5.1 系统概述

根据目标简述，设计了系统的界面，系统的功能介绍罗列在表 4-3 中。

表 4-3 本项目的具体功能介绍。

Table 4-3 Specific functions of this project.

分区	控件名称说明	功能
功能区	按钮“加载图像”	加载 CT 图像
	按钮“多器官分割”	调用分割模型对 CT 图像进行多器官分割
	按钮“器官检测”	调用检测算法对多器官进行边缘检测
	按钮“基于 CTPA 的肺栓塞分割”	调用基于 CTPA 的分割模型进行肺栓塞分割
	按钮“基于 NCCT 的肺栓塞分割”	调用基于 NCCT 的分割模型进行肺栓塞分割
	按钮“骨头”	单独显示骨头的分割结果
	按钮“肺野”	单独显示肺野的分割结果
	按钮“心脏”	单独显示心脏的分割结果
	按钮“肺动脉”	单独显示肺动脉的分割结果
显示区	按钮“气道”	单独显示气道的分割结果
	矢状	显示 CT 图像的矢状面
	冠状	显示 CT 图像的冠状面
	胸部-计算机断层扫描图像	显示 CT 图像的轴状面
	胸部多器官示意图等	直观显示胸部多器官的 3D 结构
控制区	底部显示	显示多个水平面的轴状切片
	滑动切片控制	任意选择不同的切片进行观察

4.5.2 系统功能测试

步骤说明：

（1）运行图形用户界面：左上角提供了“加载图像”“多器官分割”“基于 CTPA 的肺栓塞分割”“基于 NCCT 的肺栓塞分割”和“器官检测”按钮；左侧、中间以及下侧为图像显示区，右下角提供了切片控制；右侧提供了器官选择功

能按钮，可对骨头、肺野、心脏、肺动脉、气道和肺栓塞的分割结果进行单独展示，如图 4-8 所示。



图 4-8 图形用户界面。

Fig.4-8 Graphical user interface.

(2) 点击按钮“加载图像”，选择测试数据所在的文件夹位置后，将以矢状面、冠状面及轴状面多个维度进行展示，如图 4-9~4-10 所示。




图 4-9 加载测试 CTPA 图像数据。

Fig.4-9 Loading test CTPA image data.



图 4-10 展示了矢状面、冠状面及轴状面三个维度。

Fig.4-10 Three dimensions are shown: sagittal, coronal, and axial.




图 4-11 显示 CTPA 图像的胸部多器官的分割结果。

Fig.4-11 Displays the segmentation results of multiple chest organs on CTPA images.

(3) 点击“多器官分割”按钮，系统将显示胸部多器官的分割结果，当选择 CT 图像为 CTPA 时,胸部多器官分割结果图 4-11 所示;当选择 CT 图像为 NCCT 时，胸部多器官分割结果图 4-12 所示。用户可以通过右下角的切片控制进行连续阅片，从而查看当前切片在整体图像中的位置。

(4) 点击“基于 CTPA 的肺栓塞分割”按钮，系统将显示基于 CTPA 图像的肺栓塞的分割结果，如图 4-13 所示。




图 4-12 显示 NCCT 图像的胸部多器官的分割结果。

Fig.4-12 Displays the segmentation results of multiple chest organs on NCCT images.



图 4-13 CTPA 图像的显示肺栓塞的分割结果。

Fig.4-13 Displays the segmentation results of PE on CTPA images.

(5) 点击“基于 NCCT 的肺栓塞分割”按钮，系统将显示基于 NCCT 图像的肺栓塞的分割结果，如图 4-14 所示。



图 4-14 NCCT 图像的显示肺栓塞的分割结果。

Fig.4-14 Displays the segmentation results of PE on NCCT images.



图 4-15 显示胸部多器官的边缘检测结果。

Fig.4-15 Displays the edge detection results of multiple organs in the chest.

- (6) 点击按钮“器官检测”，显示胸部多器官边缘检测结果，如图 4-15 所示。
- (7) 系统提供了器官选择选项，用户可通过点击“骨头”“肺野”“心脏”“肺动脉”“气道”“肺栓塞”按钮，分别查看相应器官的分割结果。以“肺栓塞”为例，其分割结果独立展示，如图 4-16 所示。

(8) 点击左上角的关闭键，关闭系统界面，如图 4-17 所示。



图 4-16 单独显示肺栓塞的分割结果。

Fig.4-16 Displays the segmentation results of PE alone.




图 4-17 关闭系统界面。

Fig.4-17 Close the system interface.

4.6 本章讨论与结论

本章旨在构建一套高效的胸部结构自动分割系统，系统的核心功能涵盖了

数据输入、多器官分割、肺栓塞分割、器官检测、图像展示、切片控制、功能切换以及器官选择等基本操作。首先，针对当前胸部多器官分割任务中存在的数据集不足、标注不完全等问题，本章构建了一个包含多种胸部器官的标准数据集，为后续的算法开发与实验提供了可靠的数据支持。其次，采用基于深度学习的分割模型实现了对胸部多器官的全自动分割。在实验结果中，五类器官的分割性能表现优异，DSC 的平均值为 0.939，Sensitivity 的平均值为 0.938，Accuracy 的平均值为 0.943。表明模型在器官分割任务中的有效性。在此基础上，本章设计并实现了一种基于最短路径算法的多器官边缘检测方法，能够有效提取各个器官的边缘信息，为后续的临床诊断提供更加精确的器官轮廓数据。在实现了上述两个核心功能后，利用 Python 图形化界面编程工具设计并开发了系统的图形用户界面，确保系统在功能和交互性上的高效性与便捷性。该系统的操作流程简单直观。用户首先通过图形用户界面加载 CT 图像序列，接着调用 AI 模型接口 1 执行胸部多器官结构的分割，调用 AI 模型接口 2 或接口 3 执行肺栓塞的分割。借助功能切换模块，用户可以选择启用 AI 模型接口 4 进行器官的边缘检测。此外，系统还提供器官选择功能，用户可以单独展示骨头、肺野、心脏、肺动脉、气道和肺栓塞等不同器官或病变的分割结果。通过切片控制功能实现连续的图像浏览，便于用户对 CT 图像进行详细分析。同时，系统配备了胸部多器官的 3D 立体示意图，直观展示胸部器官的三维结构。

本章的创新主要体现在以下两个方面：首先，系统能够从 CT 图像中自动分割并识别骨头、肺野、心脏、肺动脉、气道五大类器官以及肺栓塞病变，可以为建立诊断与治疗定量模型提供支持。其次，本章设计并开发了胸部多器官结构自动分割系统的图形用户界面，提供了一个友好且高效的交互界面。该界面能够帮助医生更快速、准确地识别胸部结构，从而提高诊疗效率和准确度。

第五章 总结与展望

5.1 本文工作总结

本文从 CTPA 图像肺栓塞自动分割、NCCT 图像肺栓塞自动分割和胸部结构自动分割系统三个研究内容对肺栓塞识别深度学习模型展开了研究，完成了以下工作：

(1) CTPA 图像肺栓塞自动分割：针对现有方法在肺栓塞分割中的局限，特别是组织间相似性、肺栓塞尺寸小、以及形态和位置的多变性，提出了 DMCD-Net 方法。该方法通过模拟多模态 CT 图像的协作诊断模式，学习肺栓塞与周围组织的强度差异，从而有效减少假阳性分割，尤其在处理尺寸微小和组织间相似的区域时表现突出。此外，引入了交叉监督策略和难度感知损失函数，增强了模型对形态不规则、位置多变区域的关注。

(2) NCCT 图像肺栓塞自动分割：尽管 CTPA 在肺栓塞诊断中具有较高的诊断价值，但其对比剂的使用可能带来一定的风险，如对患者肾功能或过敏反应的潜在不良影响。因此，如何在减少对比剂使用的同时保持影像诊断精度成为关键问题。为此，本文通过引入自监督学习技术，提出了一种新的肺栓塞分割方法，有效解决了这一问题。

(3) 胸部结构自动分割系统：针对 CT 图像，本文构建了一种自动分割和识别五大胸部器官（骨头、肺野、心脏、肺动脉、气道）及肺栓塞病变的系统，为临床诊断和治疗提供支持。同时，本章设计并开发了友好且高效的图形用户界面，帮助医生快速、准确地识别胸部结构，提高诊疗效率和准确性。

(4) 本文通过详尽的对比实验和消融实验，深入分析了所提出方法在肺栓塞分割任务中的表现。实验结果表明，所提出的方法优于现有技术，并通过与现有方法的对比验证了其可行性。

5.2 未来工作展望

本文对肺栓塞识别深度学习模型进行了深入研究，取得了显著的进展，但仍存在一些尚未解决的问题。未来的研究工作可以从以下三个方面展开：

(1) 优化肺栓塞分割模型：尽管本文提出的 DMCD-Net 和 MCAMIM 模型在肺栓塞分割任务中表现出色，但在处理小体积病变和复杂形态的肺栓塞时仍存在一定的局限性。未来的研究可以进一步探索小目标检测的方法，并探索结合其他模态的医学影像数据和临床症状的数据进行更全面的分析。

(2) 半监督与自监督学习的应用：获取高质量的标注数据是医学影像分析中的一大挑战。未来的研究可以进一步探索半监督学习和自监督学习方法，减少对大量标注数据的依赖。通过利用未标注数据或弱标注数据，结合对比学习和掩码图像建模等技术，提升模型在数据稀缺情况下的泛化能力。此外，可以研究如何将自监督学习与多模态数据结合，进一步提升模型的自主学习能力。

(3) 临床应用的落地与优化：尽管本文提出的方法在测试集上表现较好，但在实际临床部署中仍面临多方面挑战。首先，当前模型的训练与评估尚未覆盖来自不同设备厂商、成像协议及复杂病理类型的真实多中心临床场景，难以充分验证其在跨机构数据下的泛化能力。临床实际应用中，CT 图像在层厚、重建算法、伪影干扰及对比剂使用方式等方面的差异，可能导致模型在非训练域下出现性能退化，进而影响诊断可靠性。为此，后续研究将进一步拓展数据来源，构建涵盖多设备、多病种、多协议的异构临床影像数据集，以提升模型在不同中心之间的鲁棒性和稳定性。其次，虽然本文已开发了支持肺栓塞及胸部多器官结构可视化识别的图形用户界面，并完成了基本功能测试，提升了系统的交互性与临床友好性，但目前系统仍运行于研究环境，尚未量化其在真实临床工作流程中的运行效率，如单病例处理耗时、显存占用率及对硬件资源的依赖等。为实现高效部署与边缘化应用，后续将围绕模型剪枝、参数量化、知识蒸馏等轻量化策略开展工作，降低模型复杂度与硬件依赖。

参考文献

- [1] 韩英. 心血管疾病诊疗进展[M]: 辽宁科学技术出版社, 2021.
- [2] Raskob GE, Angchaisuksiri P, Blanco AN, et al. Thrombosis: a major contributor to global disease burden[J]. *Arteriosclerosis, thrombosis, and vascular biology*, 2014, 34(11): 2363-71.
- [3] Jim E Nez D, de Miguel-D I Ez J, Guijarro R, et al. Trends in the management and outcomes of acute pulmonary embolism: analysis from the RIETE registry[J]. *J Am Coll Cardiol*, 2016, 67(2): 162-70.
- [4] Cohen AT, Agnelli G, Anderson FA, et al. The number of VTE events and associated morbidity and mortality[J]. *Thromb Haemost*, 2007, 98(4): 756-64.
- [5] Leung AN, Bull TM, Jaeschke R, et al. American Thoracic Society documents: an official American Thoracic Society/Society of Thoracic Radiology clinical practice guideline—evaluation of suspected pulmonary embolism in pregnancy[J]. *Radiology*, 2012, 262(2): 635-46.
- [6] 国家, 杨媛华, 翟振国, 等. 急性肺血栓栓塞症患者 516 例临床表现分析[J]. *Zhonghua Yi Xue Za Zhi*, 2006, 86(31): 2161-5.
- [7] Le Gal GEG, Bounameaux H. Diagnosing pulmonary embolism: running after the decreasing prevalence of cases among suspected patients[J]. *J Thromb Haemost*, 2004, 2(8): 1244-6.
- [8] Yuan R, Shuman WP, Earls JP, et al. Reduced iodine load at CT pulmonary angiography with dual-energy monochromatic imaging: comparison with standard CT pulmonary angiography—a prospective randomized trial[J]. *Radiology*, 2012, 262(1): 290-7.
- [9] Kligerman SJ, Mitchell JW, Sechrist JW, et al. Radiologist performance in the detection of pulmonary embolism: features that favor correct interpretation and risk factors for errors[J]. *J Thorac Imaging*, 2018, 33(6): 350-7.
- [10] Huang S, Kothari T, Banerjee I, et al. PENet—a scalable deep-learning model for automated diagnosis of pulmonary embolism using volumetric CT imaging[J]. *NPJ Digit Med*, 2020, 3(1): 61.
- [11] Li H, Pan Y, Zhao J, et al. Skin disease diagnosis with deep learning: A review[J]. *Neurocomputing*, 2021, 464: 364-93.
- [12] Azad R, Aghdam EK, Rauland A, et al. Medical image segmentation review: The success of u-net[J]. *IEEE Trans Pattern Anal Mach Intell*, 2024.
- [13] Tran KA, Kondrashova O, Bradley A, et al. Deep learning in cancer diagnosis, prognosis and treatment selection[J]. *Genome Med*, 2021, 13: 1-17.
- [14] Konstantinides SV, Meyer G, Becattini C, et al. 2019 ESC Guidelines for the diagnosis and management of acute pulmonary embolism developed in collaboration with the European Respiratory Society (ERS) The Task Force for the diagnosis and management of acute pulmonary embolism of the European Society of Cardiology (ESC)[J]. *Eur Heart J*, 2020, 41(4): 543-603.
- [15] McCullough PA. Contrast-induced acute kidney injury[J]. *J Am Coll Cardiol*, 2008, 51(15): 1419-28.

- [16] Bottinor W, Polkampally P, Jovin I. Adverse reactions to iodinated contrast media[J]. *Int J Angiol*, 2013, 22(03): 149-54.
- [17] Uchida N, Sekino M, Kimoto A, et al. The pathophysiology of anaphylactic shock captured on computed tomography images[J]. *Intensive Care Med*, 2023, 49(12): 1544-5.
- [18] Masutani Y, MacMahon H, Doi K. Computerized detection of pulmonary embolism in spiral CT angiography based on volumetric image analysis[J]. *IEEE Trans Med Imaging*, 2002, 21(12): 1517-23.
- [19] Bouma H, Sonnemans JJ, Vilanova A, et al. Automatic detection of pulmonary embolism in CTA images[J]. *IEEE Trans Med Imaging*, 2009, 28(8): 1223-30.
- [20] Das M, M U Hlenbruch G, Helm A, et al. Computer-aided detection of pulmonary embolism: influence on radiologists' detection performance with respect to vessel segments[J]. *Eur Radiol*, 2008, 18: 1350-5.
- [21] Wittenberg R, Peters JF, Sonnemans JJ, et al. Impact of image quality on the performance of computer-aided detection of pulmonary embolism[J]. *AJR Am J Roentgenol*, 2011, 196(1): 95-101.
- [22] Tajbakhsh N, Gotway MB, Liang J. Computer-aided pulmonary embolism detection using a novel vessel-aligned multi-planar image representation and convolutional neural networks[C]: Springer, 2015: 62-9.
- [23] Tajbakhsh N, Shin JY, Gotway MB, et al. Computer-aided detection and visualization of pulmonary embolism using a novel, compact, and discriminative image representation[J]. *Med Image Anal*, 2019, 58: 101541.
- [24] Long K, Tang L, Pu X, et al. Probability-based Mask R-CNN for pulmonary embolism detection[J]. *Neurocomputing*, 2021, 422: 345-53.
- [25] Ma X, Ferguson EC, Jiang X, et al. A multitask deep learning approach for pulmonary embolism detection and identification[J]. *Sci Rep*, 2022, 12(1): 13087.
- [26] Lynch D, Suriya M. PE-DeepNet: A deep neural network model for pulmonary embolism detection[J]. *International Journal of Intelligent Networks*, 2022, 3: 176-80.
- [27] Vainio T, M A Kel A T, Arkko A, et al. Leveraging open dataset and transfer learning for accurate recognition of chronic pulmonary embolism from CT angiogram maximum intensity projection images[J]. *Eur Radiol Exp*, 2023, 7(1): 33.
- [28] Islam NU, Zhou Z, Gehlot S, et al. Seeking an optimal approach for Computer-aided Diagnosis of Pulmonary Embolism[J]. *Med Image Anal*, 2024, 91: 102988.
- [29] Chen L, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C], 2018: 801-18.
- [30] Yu F. Multi-scale context aggregation by dilated convolutions[J]. *arXiv preprint arXiv:1511.07122*, 2015.
- [31] Schlemper J, Oktay O, Schaap M, et al. Attention gated networks: Learning to leverage salient regions in medical images[J]. *Med Image Anal*, 2019, 53: 197-207.

- [32] Sinha A, Dolz J. Multi-scale guided attention for medical image segmentation. arXiv preprint arXiv: 190602849[J], 2019.
- [33] Isensee F, Jaeger PF, Kohl SA, et al. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation[J]. Nat Methods, 2021, 18(2): 203-11.
- [34] Cao H, Wang Y, Chen J, et al. Swin-unet: Unet-like pure transformer for medical image segmentation[C]: Springer, 2022: 205-18.
- [35] Chen J, Lu Y, Yu QT. Transformers make strong encoders for medical image segmentation. arxiv 2021[J]. arXiv preprint arXiv:2102.04306.
- [36] Cano-Espinosa C, Cazorla M, Gonz A Lez GAN. Computer aided detection of pulmonary embolism using multi-slice multi-axial segmentation[J]. Applied Sciences, 2020, 10(8): 2945.
- [37] Liu Z, Yuan H, Wang H. CAM-Wnet: An effective solution for accurate pulmonary embolism segmentation[J]. Med Phys, 2022, 49(8): 5294-303.
- [38] Yu C, Chang M, Cheng Y, et al. Convolutional neural network for early pulmonary embolism detection via computed tomography pulmonary angiography[J]. arXiv preprint arXiv:2204.03204, 2022.
- [39] Guo J, Liu X, Chen Y, et al. AANet: artery-aware network for pulmonary embolism detection in CTPA images[C]: Springer, 2022: 473-83.
- [40] Pu J, Gezer NS, Ren S, et al. Automated detection and segmentation of pulmonary embolisms on computed tomography pulmonary angiography (CTPA) using deep learning but without manual outlining[J]. Med Image Anal, 2023, 89: 102882.
- [41] Chen Y, Zou B, Guo Z, et al. Scunet++: Swin-unet and cnn bottleneck hybrid architecture with multi-fusion dense skip connection for pulmonary embolism ct image segmentation[C], 2024: 7759-67.
- [42] Wen Z, Wang H, Yuan H, et al. A method of pulmonary embolism segmentation from CTPA images based on U-net[C]: IEEE, 2019: 31-5.
- [43] Kervadec H, Bouchtiba J, Desrosiers C, et al. Boundary loss for highly unbalanced segmentation[C]: PMLR, 2019: 285-96.
- [44] Du J, Guan K, Liu P, et al. Boundary-sensitive loss function with location constraint for hard region segmentation[J]. IEEE J Biomed Health Inform, 2022, 27(2): 992-1003.
- [45] Liu X, Yang L, Chen J, et al. Region-to-boundary deep learning model with multi-scale feature fusion for medical image segmentation[J]. Biomed Signal Process Control, 2022, 71: 103165.
- [46] Fang L, Wang X. Brain tumor segmentation based on the dual-path network of multi-modal MRI images[J]. Pattern Recognit, 2022, 124: 108434.
- [47] Li J, Gao G, Yang L, et al. DPF-Net: A dual-path progressive fusion network for retinal vessel segmentation[J]. IEEE Trans Instrum Meas, 2023.
- [48] Lee D, Kim J, Moon W, et al. CollaGAN: Collaborative GAN for missing image data imputation[C], 2019: 2487-96.
- [49] Dar SU, Yurt M, Karacan L, et al. Image synthesis in multi-contrast MRI with conditional

- generative adversarial networks[J]. IEEE Trans Med Imaging, 2019, 38(10): 2375-88.
- [50] Sharma A, Hamarneh G. Missing MRI pulse sequence synthesis using multi-modal generative adversarial network[J]. IEEE Trans Med Imaging, 2019, 39(4): 1170-83.
- [51] Liu J, Tian Y, A U G I Ldere AMCS, et al. DyeFreeNet: Deep virtual contrast CT synthesis[C]: Springer, 2020: 80-9.
- [52] Seo M, Kim D, Lee K, et al. Neural contrast enhancement of CT image[C], 2021: 3973-82.
- [53] Zhong L, Huang P, Shu H, et al. United multi-task learning for abdominal contrast-enhanced CT synthesis through joint deformable registration[J]. Comput Methods Programs Biomed, 2023, 231: 107391.
- [54] Zhong L, Chen Z, Shu H, et al. Multi-Scale Tokens-Aware Transformer Network for Multi-Region and Multi-Sequence MR-to-CT Synthesis in a Single Model[J]. IEEE Trans Med Imaging, 2023.
- [55] Zhang W, Zhou Z, Gao Z, et al. Multiple adversarial learning based angiography reconstruction for ultra-low-dose contrast medium CT[J]. IEEE J Biomed Health Inform, 2022, 27(1): 409-20.
- [56] Yang H, Sun J, Carass A, et al. Unsupervised MR-to-CT synthesis using structure-constrained CycleGAN[J]. IEEE Trans Med Imaging, 2020, 39(12): 4249-61.
- [57] Zhang Y, Zhong L, Shu H, et al. Cross-task feedback fusion gan for joint mr-ct synthesis and segmentation of target and organs-at-risk[J]. IEEE Trans Artif Intell, 2022, 4(5): 1246-57.
- [58] Liu F, Cai J, Huo Y, et al. Jssr: A joint synthesis, segmentation, and registration system for 3d multi-modal image alignment of large-scale pathological ct scans[C]: Springer, 2020: 257-74.
- [59] Pang H, Qi S, Wu Y, et al. NCCT-CECT image synthesizers and their application to pulmonary vessel segmentation[J]. Comput Methods Programs Biomed, 2023, 231: 107389.
- [60] Peng J, Liu Y, Jiang D, et al. Deep Learning and GAN-Synthesis for Auto-Segmentation of Pancreatic Cancer by Non-Enhanced CT for Adaptive Radiotherapy[J]. International Journal of Radiation Oncology, Biology, Physics, 2023, 117(2): e499-500.
- [61] Thorwarth D. Functional imaging for radiotherapy treatment planning: current status and future directions—a review[J]. The British journal of radiology, 2015, 88(1051): 20150056.
- [62] Mehta R, Arbel T. RS-Net: Regression-segmentation 3D CNN for synthesis of full resolution missing brain MRI in the presence of tumours[C]: Springer, 2018: 119-29.
- [63] Gao Y, Ma J, Zhao M, et al. Nddr-cnn: Layerwise feature fusing in multi-task cnns by neural discriminative dimensionality reduction[C], 2019: 3205-14.
- [64] Luo Y, Nie D, Zhan B, et al. Edge-preserving MRI image synthesis via adversarial network with iterative multi-scale fusion[J]. Neurocomputing, 2021, 452: 63-77.
- [65] Yang Y, Iwamoto Y, Chen Y, et al. Synthesizing contrast-enhanced computed tomography images with an improved conditional generative adversarial network[C]: IEEE, 2022: 2097-100.
- [66] Xu C, Song Y, Zhang D, et al. Spatiotemporal knowledge teacher--student reinforcement learning to detect liver tumors without contrast agents[J]. Med Image Anal, 2023, 90: 102980.
- [67] Cao K, Xia Y, Yao J, et al. Large-scale pancreatic cancer detection via non-contrast CT and deep

- learning[J]. Nat Med, 2023, 29(12): 3033-43.
- [68] Ma Y, Hua Y, Deng H, et al. Self-supervised vessel segmentation via adversarial learning[C], 2021: 7536-45.
- [69] Shabani S, Homayounfar M, Vardhanabhuti V, et al. Self-supervised region-aware segmentation of COVID-19 CT images using 3D GAN and contrastive learning[J]. Comput Biol Med, 2022, 149: 106033.
- [70] Jiao J, Namburete AI, Papageorghiou AT, et al. Self-supervised ultrasound to MRI fetal brain image synthesis[J]. IEEE Trans Med Imaging, 2020, 39(12): 4413-24.
- [71] He K, Chen X, Xie S, et al. Masked autoencoders are scalable vision learners[C], 2022: 16000-9.
- [72] Cai Z, Lin L, He H, et al. Uni4eye++: A general masked image modeling multi-modal pre-training framework for ophthalmic image classification and segmentation[J]. IEEE Trans Med Imaging, 2024.
- [73] Xie Y, Gu L, Harada T, et al. Rethinking masked image modelling for medical image representation[J]. Med Image Anal, 2024, 98: 103304.
- [74] Kang Q, Lao Q, Gao J, et al. Deblurring masked image modeling for ultrasound image analysis[J]. Med Image Anal, 2024, 97: 103256.
- [75] Litjens G, Kooi T, Bejnordi BE, et al. A survey on deep learning in medical image analysis[J]. Med Image Anal, 2017, 42: 60-88.
- [76] Xie Y, Zhang J, Lu H, et al. SESV: Accurate medical image segmentation by predicting and correcting errors[J]. IEEE Trans Med Imaging, 2020, 40(1): 286-96.
- [77] Cheikh AB, Gorincour G, Nivet H, et al. How artificial intelligence improves radiological interpretation in suspected pulmonary embolism[J]. Eur Radiol, 2022, 32(9): 5831-42.
- [78] Sanjeev S, Al Khatib SK, Shaaban MA, et al. PECon: Contrastive Pretraining to Enhance Feature Alignment Between CT and EHR Data for Improved Pulmonary Embolism Diagnosis[C]: Springer, 2023: 434-43.
- [79] Santini G, Zumbo LM, Martini N, et al. Synthetic contrast enhancement in cardiac CT with Deep Learning[J]. arXiv preprint arXiv:1807.01779, 2018.
- [80] Buhmann S, Herzog P, Liang J, et al. Clinical evaluation of a computer-aided diagnosis (CAD) prototype for the detection of pulmonary embolism[J]. Acad Radiol, 2007, 14(6): 651-8.
- [81] Masoudi M, Pourreza H, Saadatmand-Tarzjan M, et al. A new dataset of computed-tomography angiography images for computer-aided detection of pulmonary embolism[J]. Sci Data, 2018, 5(1): 1-9.
- [82] Gonz A Lez GAN, Jimenez-Carretero D, Rodr I Guez-L O Pez S, et al. Computer aided detection for pulmonary embolism challenge (CAD-PE)[J]. arXiv preprint arXiv:2003.13440, 2020.
- [83] Tarvainen A, Valpola H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[J]. Adv Neural Inf Process Syst, 2017, 30.
- [84] Zhou Z, Siddiquee MMR, Tajbakhsh N, et al. Unet++: Redesigning skip connections to exploit multiscale features in image segmentation[J]. IEEE Trans Med Imaging, 2019, 39(6): 1856-67.

- [85] Jha D, Smedsrud PH, Riegler MA, et al. Resunet++: An advanced architecture for medical image segmentation[C]: IEEE, 2019: 225-2255.
- [86] Feng S, Zhao H, Shi F, et al. CPFNet: Context pyramid fusion network for medical image segmentation[J]. IEEE Trans Med Imaging, 2020, 39(10): 3008-18.
- [87] Xu H, Li H, Xu Q, et al. Automatic detection of pulmonary embolism in computed tomography pulmonary angiography using Scaled-YOLOv4[J]. Med Phys, 2023, 50(7): 4340-50.
- [88] Bushra F, Chowdhury ME, Sarmun R, et al. Deep learning in computed tomography pulmonary angiography imaging: A dual-pronged approach for pulmonary embolism detection[J]. Expert Syst Appl, 2024, 245: 123029.
- [89] Atema JJ, Gans SL, Van Randen A, et al. Comparison of imaging strategies with conditional versus immediate contrast-enhanced computed tomography in patients with clinical suspicion of acute appendicitis[J]. Eur Radiol, 2015, 25: 2445-52.
- [90] Zhang LJ, Lu GM, Meinel FG, et al. Computed tomography of acute pulmonary embolism: state-of-the-art[J]. Eur Radiol, 2015, 25: 2547-57.
- [91] Sadowski EA, Bennett LK, Chan MR, et al. Nephrogenic systemic fibrosis: risk factors and incidence estimation[J]. Radiology, 2007, 243(1): 148-57.
- [92] Xu C, Xu L, Gao Z, et al. Direct delineation of myocardial infarction without contrast agents using a joint motion feature learning architecture[J]. Med Image Anal, 2018, 50: 82-94.
- [93] Azarfar G, Ko S, Adams SJ, et al. Applications of deep learning to reduce the need for iodinated contrast media for CT imaging: a systematic review[J]. Int J Comput Assist Radiol Surg, 2023, 18(10): 1903-14.
- [94] Xu C, Xu L, Ohorodnyk P, et al. Contrast agent-free synthesis and segmentation of ischemic heart disease images using progressive sequential causal GANs[J]. Med Image Anal, 2020, 62: 101668.
- [95] Zhang Q, Burrage MK, Shanmuganathan M, et al. Artificial intelligence for contrast-free MRI: scar assessment in myocardial infarction using deep learning--based virtual native enhancement[J]. Circulation, 2022, 146(20): 1492-503.
- [96] Qi R, Li X, Xu L, et al. Cardiac Physiology Knowledge-Driven Diffusion Model for Contrast-Free Synthesis Myocardial Infarction Enhancement[C]: Springer, 2024: 200-10.
- [97] Zhang W, Yin H, Huang Z, et al. Development and validation of MRI-based deep learning models for prediction of microsatellite instability in rectal cancer[J]. Cancer Med, 2021, 10(12): 4164-73.
- [98] Chatsias A, Joyce T, Giuffrida MV, et al. Multimodal MR synthesis via modality-invariant latent representation[J]. IEEE Trans Med Imaging, 2017, 37(3): 803-14.
- [99] Wang T, Lei Y, Curran WJ, et al. Contrast-enhanced MRI synthesis from non-contrast MRI using attention CycleGAN[C]: SPIE, 2021: 388-93.
- [100] Colak E, Kitamura FC, Hobbs SB, et al. The RSNA pulmonary embolism CT dataset[J]. Radiology: Artificial Intelligence, 2021, 3(2): e200254.
- [101] Hatamizadeh A, Tang Y, Nath V, et al. Transformers for 3D medical image segmentation. 2022 IEEE/CVF winter conference on applications of computer vision (WACV)[J]. Waikoloa, HI, USA:

- IEEE, 2022.
- [102] Mastora I, Remy-Jardin M, Masson P, et al. Severity of acute pulmonary embolism: evaluation of a new spiral CT angiographic score in correlation with echocardiographic data[J]. *Eur Radiol*, 2003, 13: 29-35.
- [103] Dong X, Lei Y, Wang T, et al. Automatic multiorgan segmentation in thorax CT images using U-net-GAN[J]. *Med Phys*, 2019, 46(5): 2157-68.
- [104] van Harten LD, Niothout JM, Verhoeff JJ, et al. Automatic segmentation of organs at risk in thoracic CT scans by combining 2D and 3D convolutional neural networks[C]: CEUR, 2019.
- [105] Javaid U, Dasnoy D, Lee JA. Multi-organ segmentation of chest CT images in radiation oncology: comparison of standard and dilated UNet[C]: Springer, 2018: 188-99.
- [106] Zhang L, Zhang J, Shen P, et al. Block level skip connections across cascaded V-Net for multi-organ segmentation[J]. *IEEE Trans Med Imaging*, 2020, 39(9): 2782-93.
- [107] Trullo R, Petitjean C, Dubray B, et al. Multiorgan segmentation using distance-aware adversarial networks[J]. *J Med Imaging (Bellingham)*, 2019, 6(1): 14001.
- [108] Han M, Yao G, Zhang W, et al. Segmentation of CT Thoracic Organs by Multi-resolution VB-nets.[J]. *SegTHOR@ ISBI*, 2019, 2019: 1-4.
- [109] Wu Q, Chen Q, Yu Y, et al. 3D fully convolutional network for thorax multi-organs semantic segmentation[J]. *J Mech Med Biol*, 2022, 22(03): 2240006.
- [110] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]: Springer, 2015: 234-41.
- [111] Isensee F, Petersen J, Klein A, et al. nnU-Net: Self-adapting Framework for U-Net-Based Medical Image Segmentation[C]: Springer, 2019: 22.